06_DVZ3IL: Data Visualization

03 - Visualisierungen für statistische Analyse | MTD.ba VZ WS26/27

FH-Prof. Dr. Mandy Keck
Professorin für User Experience und Interaktionsdesign

mandy.keck@fh-hagenberg.at
Department Software & AI, Raum FH 1.217
Fachhochschule Oberösterreich, Campus Hagenberg

Struktur Vorlesung

Vorlesung 1 + 2

01 **Datenvisualisierung**
Warum visualisieren?

02 **Design Triangle Framework**
Wie analysiert Nutzer:innen, Aufgaben und Daten?

03 **Datentransformation**
Wie werden die Daten für das Mapping vorbereitet?

04 **Komponenten einer Visualisierung**
Was sind die Bausteine einer Visualisierung?

05 **Expressivität und Effektivität**
Auf welche visuellen Attribute können die Datenattribute abgebildet werden?

Vorlesung 3

06 **Visualisierungen für statistische Analyse**
Wie kann man sich mit den Daten vertraut machen?

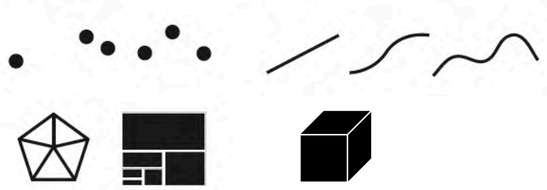
Visuelle Kodierung

Bottom-Up

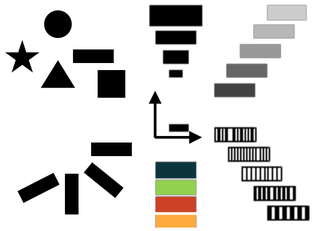
Top-Down



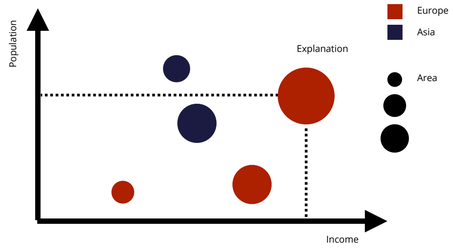
Referenzsystem



visuelle Elemente



visuelle Attribute



Kontextkomponenten



Visualisierungskomponenten

Chart Type

Visuelle Kodierung

Bottom-Up

Top-Down











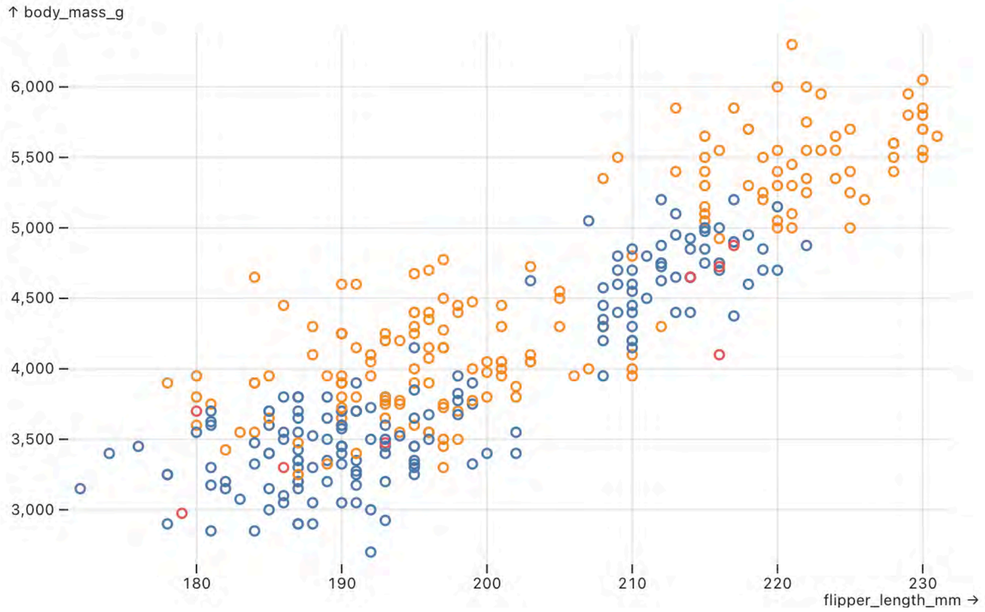


Visualisierungskomponenten

Chart Type

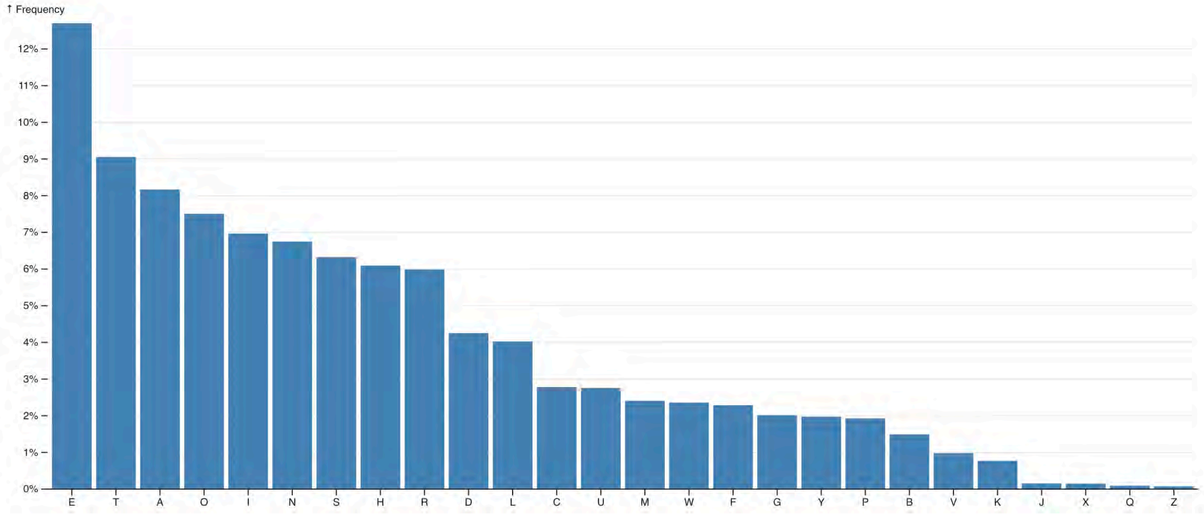
Atomare vs. aggregierte Visualisierungen

[Shneiderman 2008, Park et al. 2018]



Atomare Visualisierungen:

ein visuelles Element pro Datenobjekt



Aggregierte Visualisierungen:

ein visuelles Element kapselt mehrere Datenobjekte

06. Visualisierung für statistische Analyse

Wie kann man sich mit den Daten vertraut machen?

Auswahl von geeigneten Visualisierungen

https://www.dataviz-inspiration.com



WHAT

WHY

WHO



Übersicht Visualisierungstechniken

https://www.data-to-viz.com

https://datavizcatalogue.com/

https://www.python-graph-gallery.com/

https://www.dataviz-inspiration.com



Klassifikation von Visualisierungen

WHY



Korrelationen erkennen



Kategorien vergleichen



Verteilungen analysieren



Part of a Whole



Trends erkennen



Geographische Analyse

Statistische Analyse

Erfordert Semantische Datenstruktur

Klassifikation von Visualisierungen

WHY



Korrelationen erkennen

Kategorien vergleichen

Verteilungen analysieren

Part of a Whole

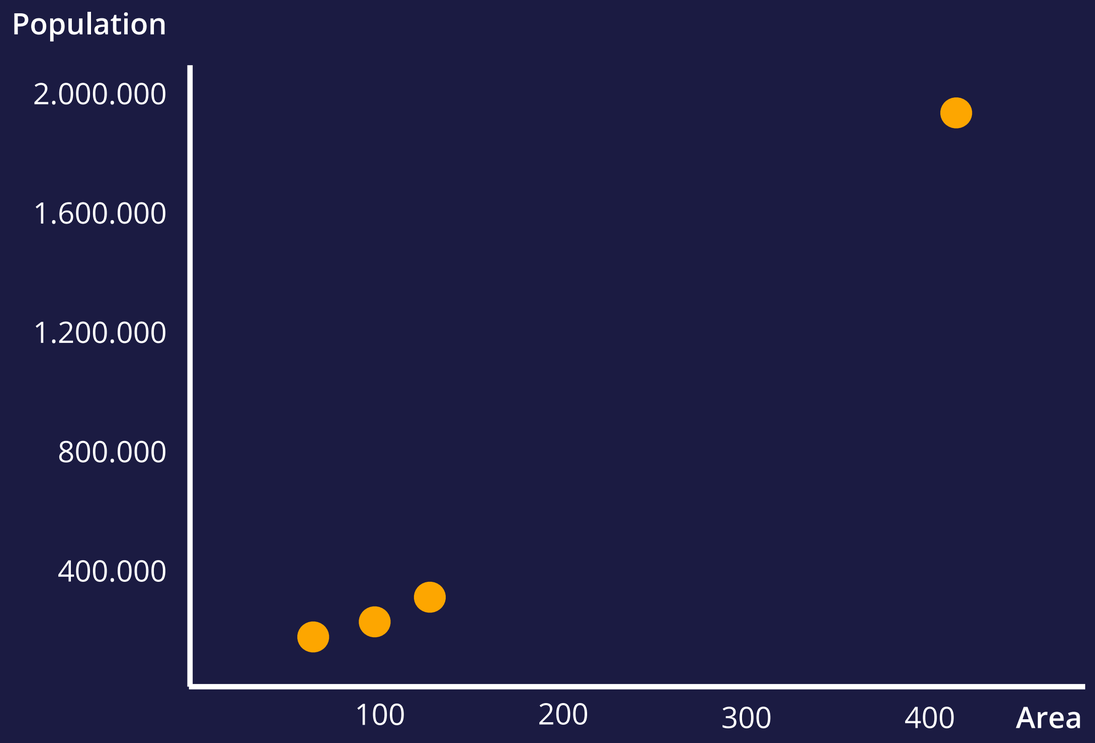
Trends erkennen



Geographische Analyse

Scatterplot (Streudiagramm)

veranschaulicht die Korrelation von zwei quantitativen Messwerten



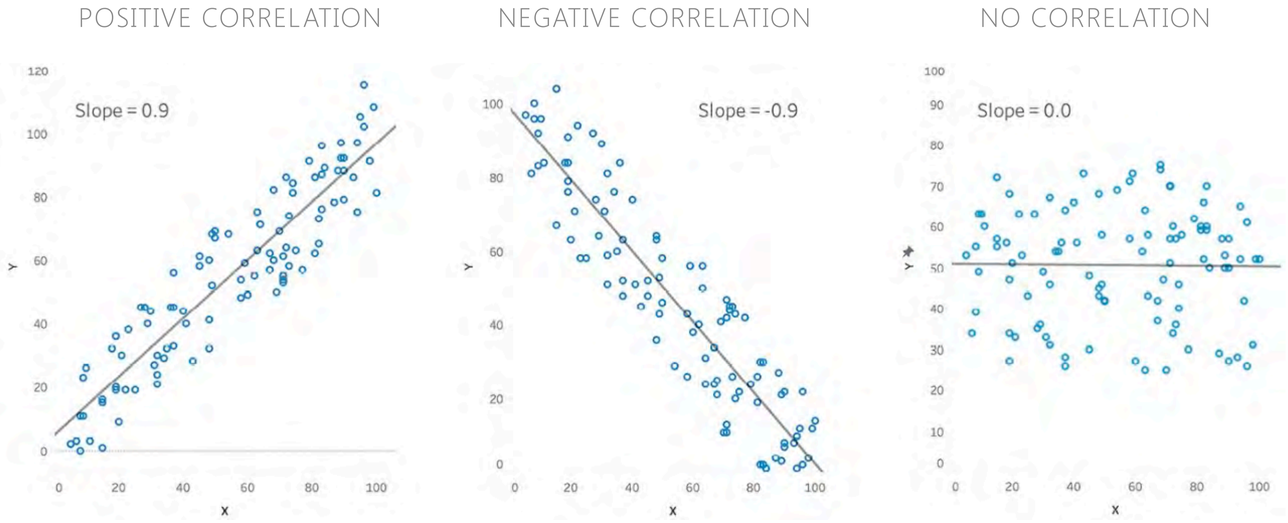
WHAT Quantitative Daten

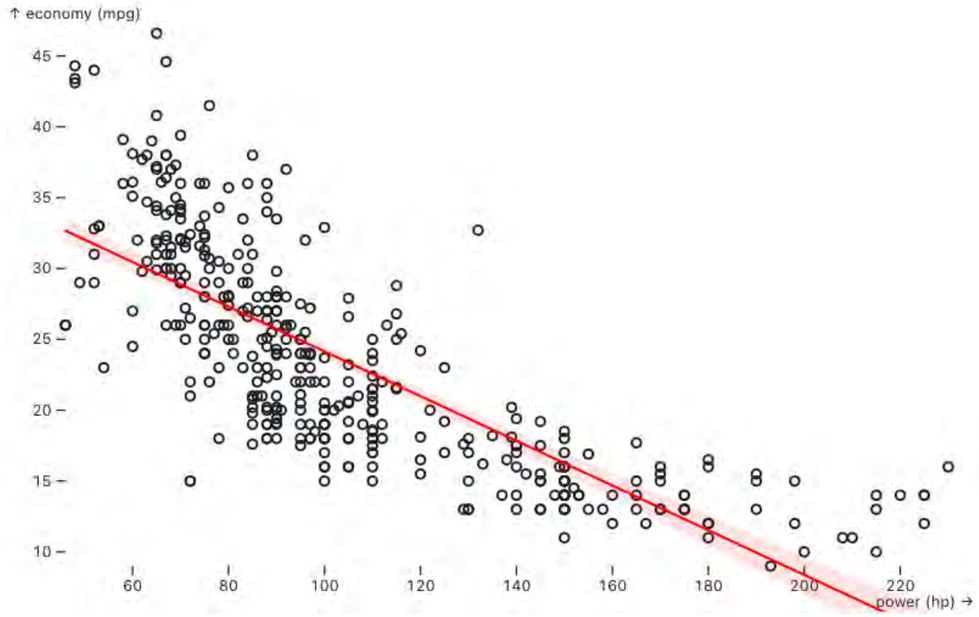
CITY	AREA	POPULATION
Graz	127	291.072
Linz	96	206.595
Salzburg	65	15.5021
Wien	414	1.911.191

WHY Erkennen von Trends, Ausreißern, Korrelationen und Clustern, Analyse von Verteilungen (Distribution)

Korrelation

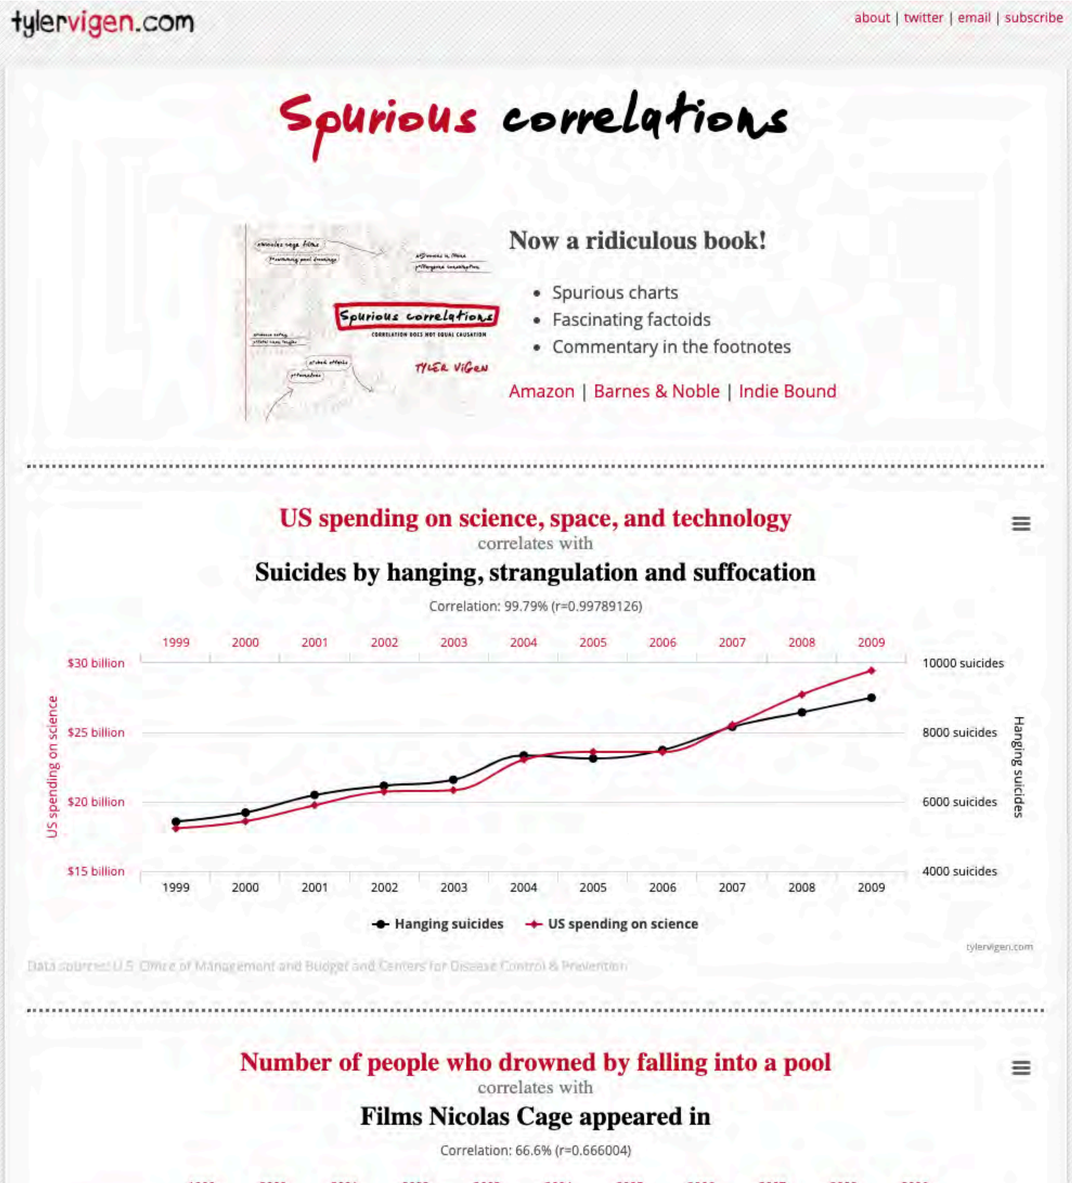
- Scatterplots eignen sich sehr gut zur Beurteilung der Korrelation zwischen zwei Merkmalen
- je stärker die Korrelation ist, desto näher liegen die Punkte an einer perfekten Diagonale
- Regressionslinien heben die Korrelation noch deutlicher hervor





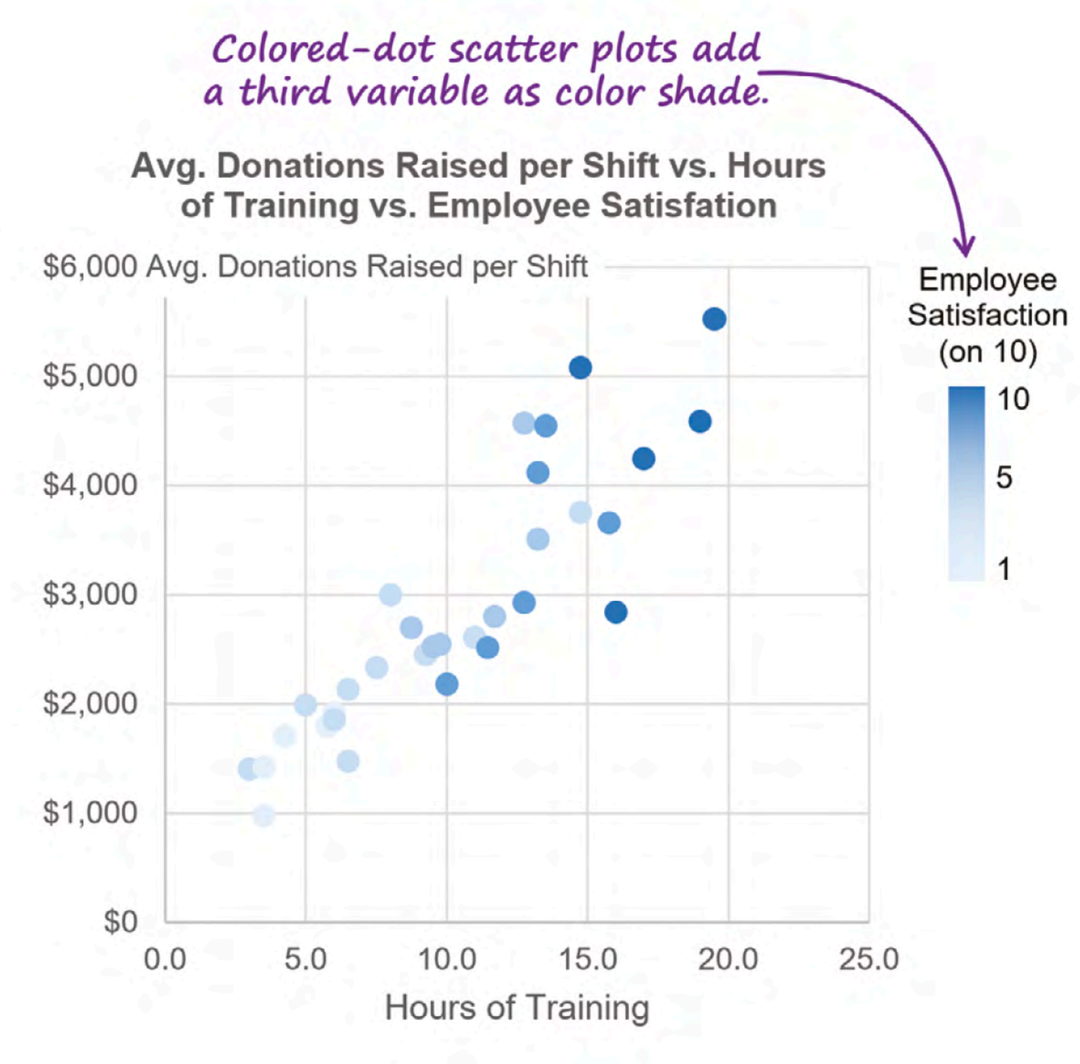
Korrelation impliziert keine Kausalität

https://www.tylervigen.com/spurious-correlations



Colored-dot Scatterplot

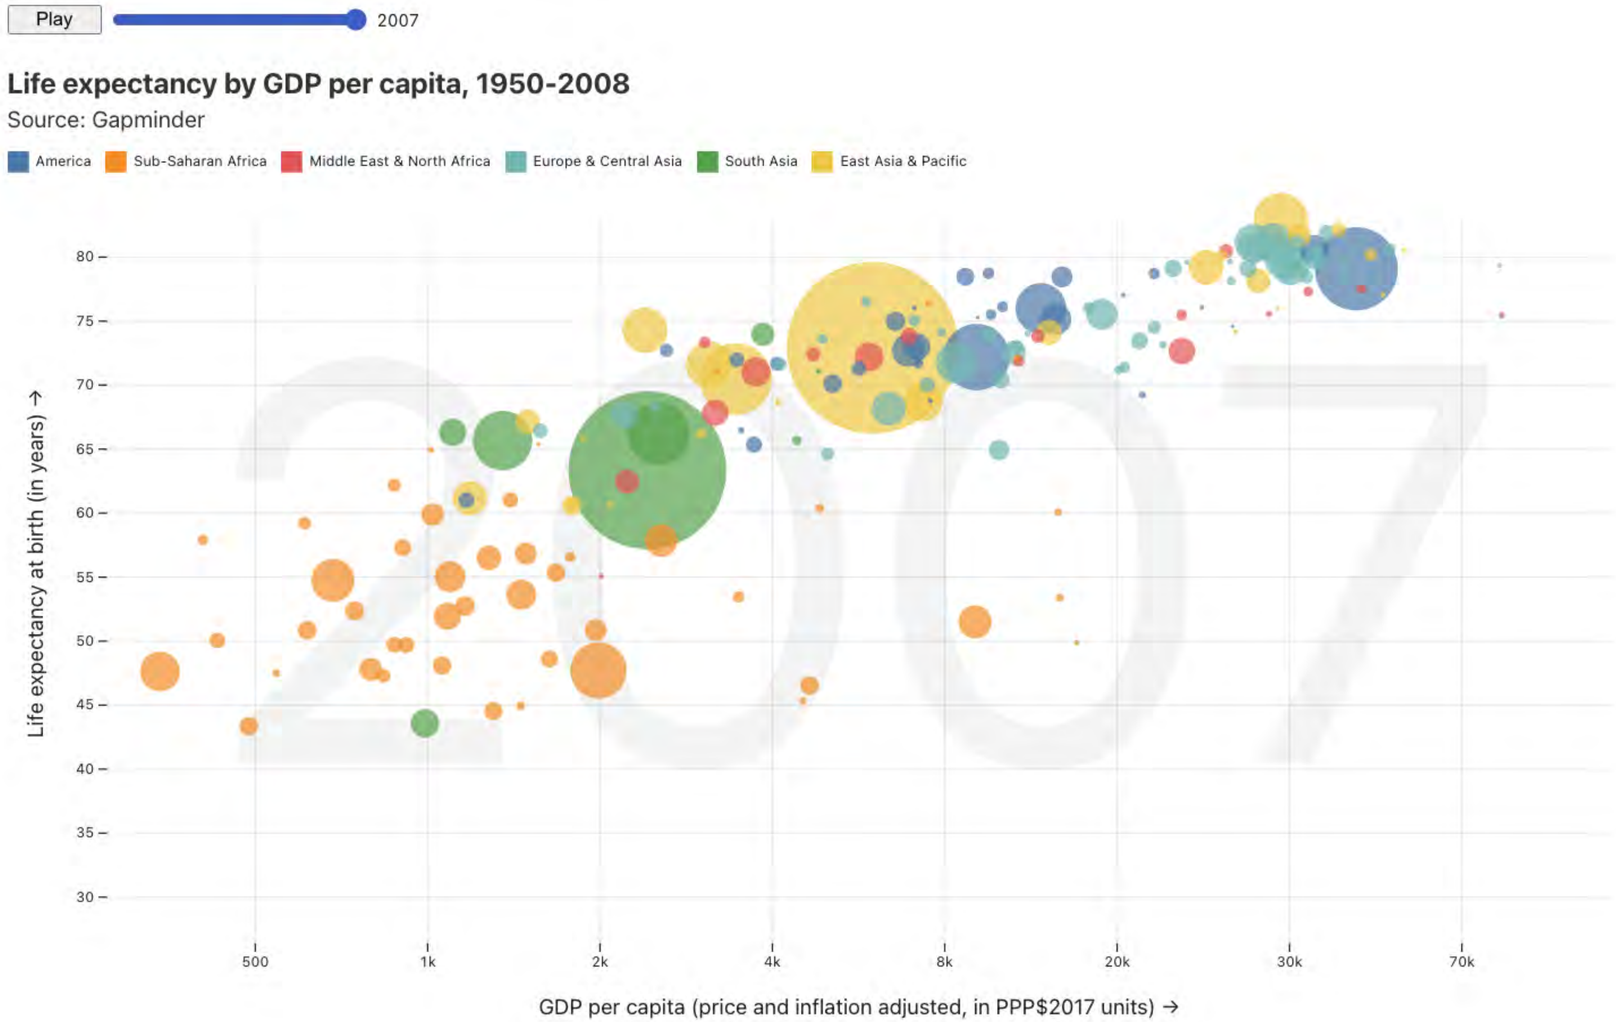
- durch die Farbabstufungen können Beziehungen zwischen drei Variablen statt nur zwei dargestellt werden
- jedoch können nur grobe Schätzungen und Vergleiche der helligkeitskodierten Werte vorgenommen werden (niedrige Effektivität von Farbhelligkeit)
- bei vielen Überlappungen der Datenpunkten werden normalerweise semi-transparente Punkte empfohlen — da diese aber die Wahrnehmung der geordneten Farbskala beeinträchtigen kann, ist hier eher ein Bubble Chart zu empfehlen



[Desberats 2023]

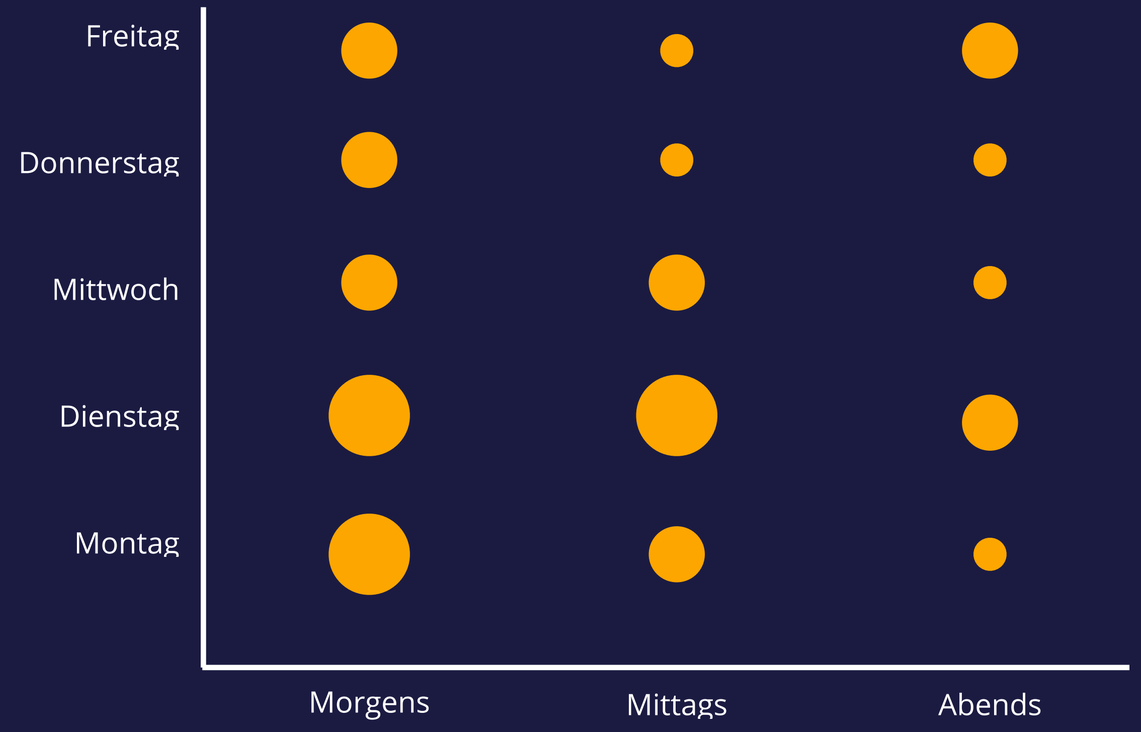
Bubble Chart

- Scatterplots können in ein Bubble Chart umgewandelt werden, indem die Größe der Kreise entsprechend einer dritten Variablen variiert werden
- die Kreise sollten nach Fläche und nicht nach Radius skaliert werden



Correlation Matrix (Scatterplot Heatmap, Matrix)

visualisiert quantitative Attribute zwischen zwei kategorischen Attributen



WHAT zwei **kategorische Attribute** (nominal oder ordinal) und ein **quantitatives Attribut**

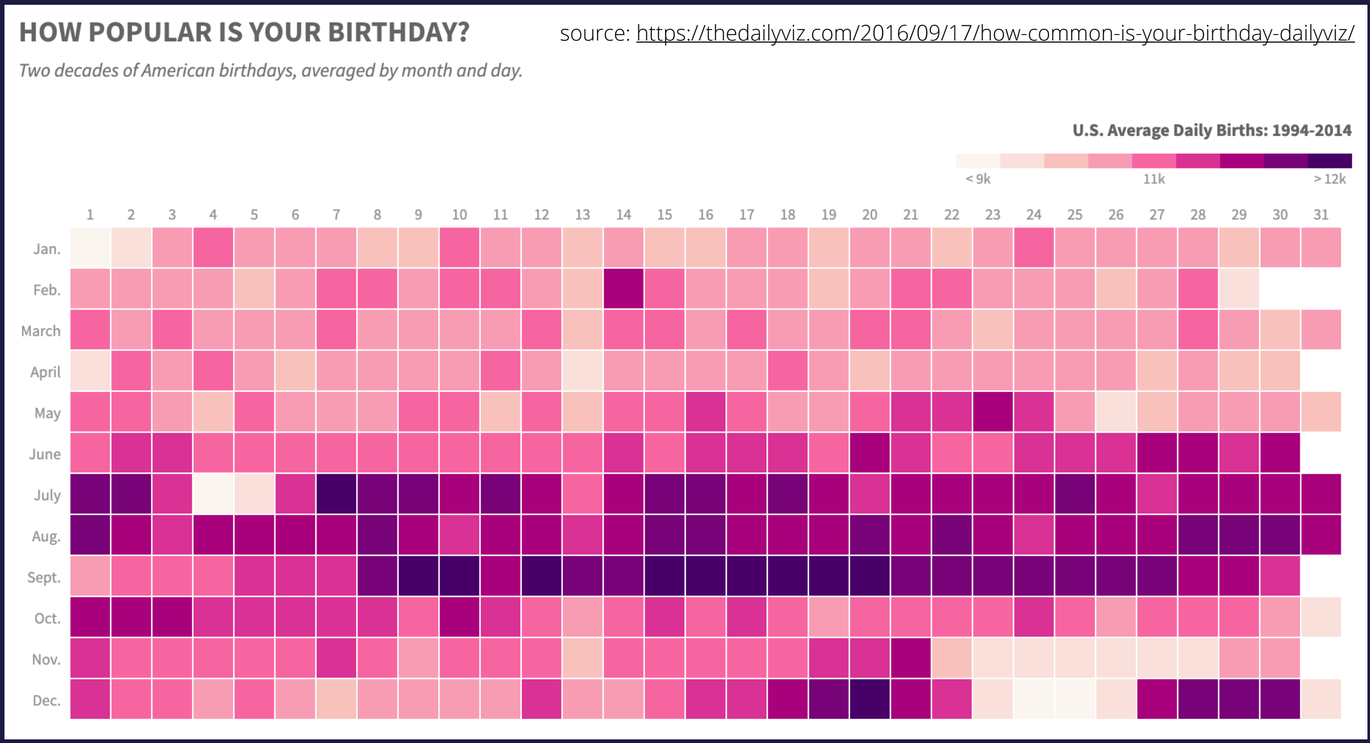
WHY Korrelationen analysieren, Cluster finden

- nutzt Tabellenlayout mit zwei kategorischen Achsen
- jede Zelle wird durch eine geometrische Form markiert, deren Größe so bemessen ist, dass sie einen quantitativen Wert darstellt

[Kirk 2019]

Heatmap

visualisiert quantitative Attribute zwischen zwei kategorischen Attributen



WHAT zwei **kategorische Attribute** (nominal oder ordinal) und ein **quantitatives Attribut**

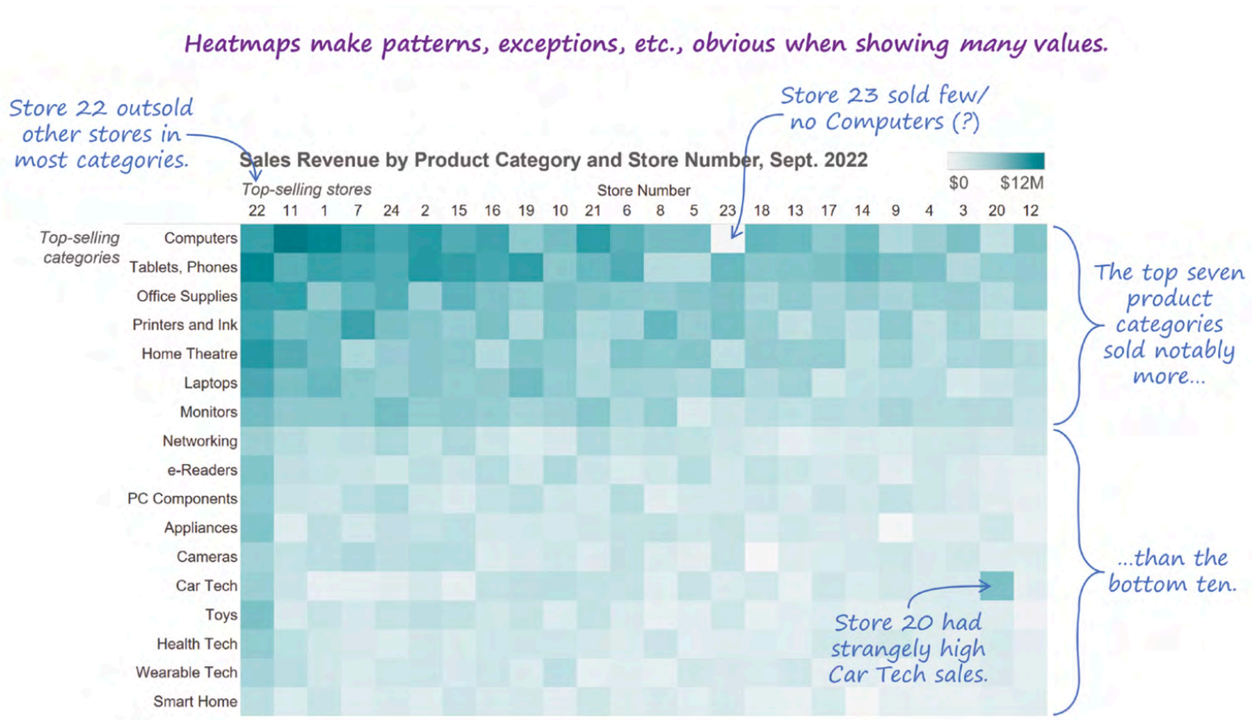
WHY Korrelationen analysieren, Cluster finden

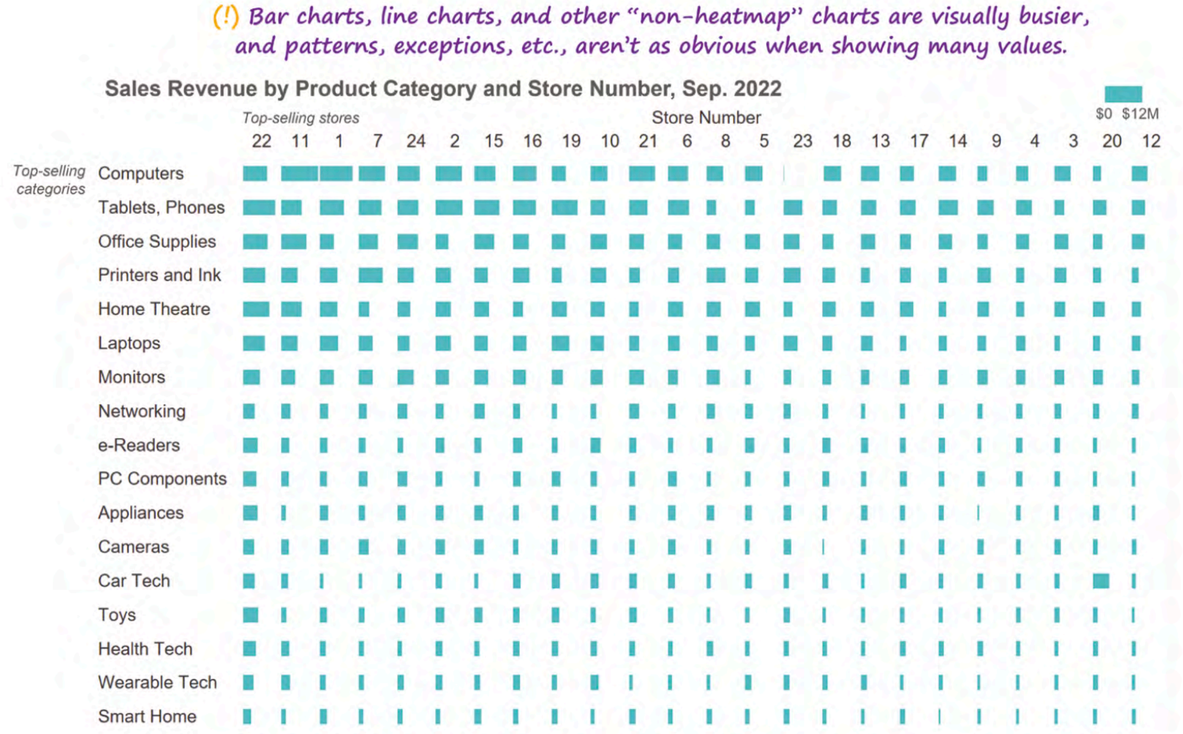
- nutzt Tabellenlayout mit zwei kategorischen Achsen
- jede Zelle wird farblich kodiert, um einen quantitativen Wert zwischen den beiden Kategorien darzustellen

[Kirk 2019]

Correlation Matrix vs. Heatmap

- bei der Darstellung einer großen Anzahl von Werten sind Heatmaps optisch weniger überladen und machen Muster und Ausreißer deutlicher erkennbar als in größenveränderte Charts
- wenn proportionale Vergleiche wichtig sind, ist die Correlation Matrix besser geeignet (Mengen lassen sich anhand der Formgröße etwas genauer vergleichen als anhand unterschiedlicher Helligkeitswerte)





[Desberats 2023]

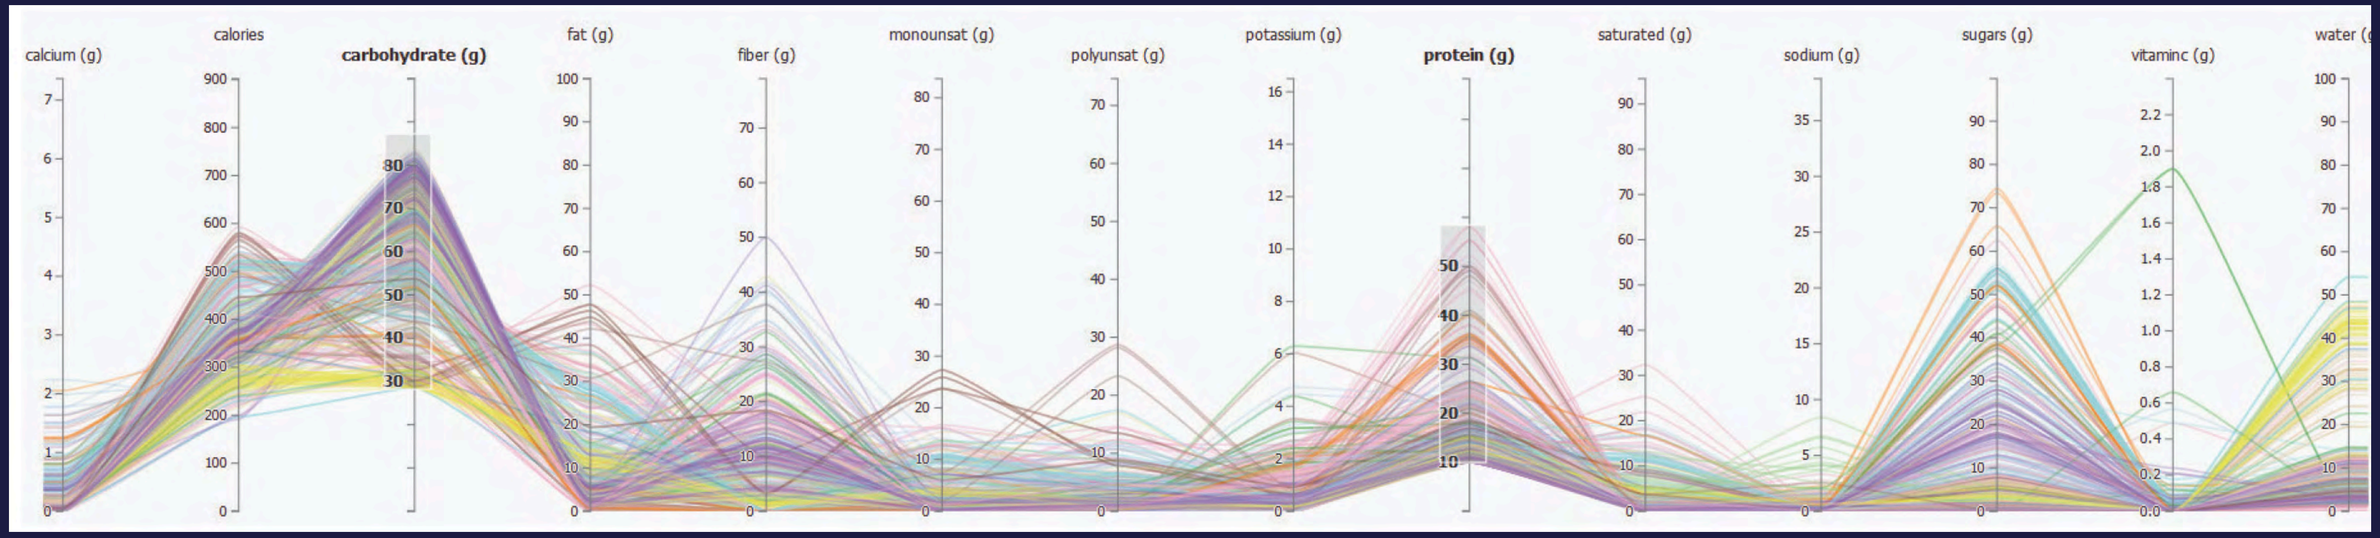
Parallel Coordinates

Parallele Koordinaten zeigen Datenelemente als Polylinien an

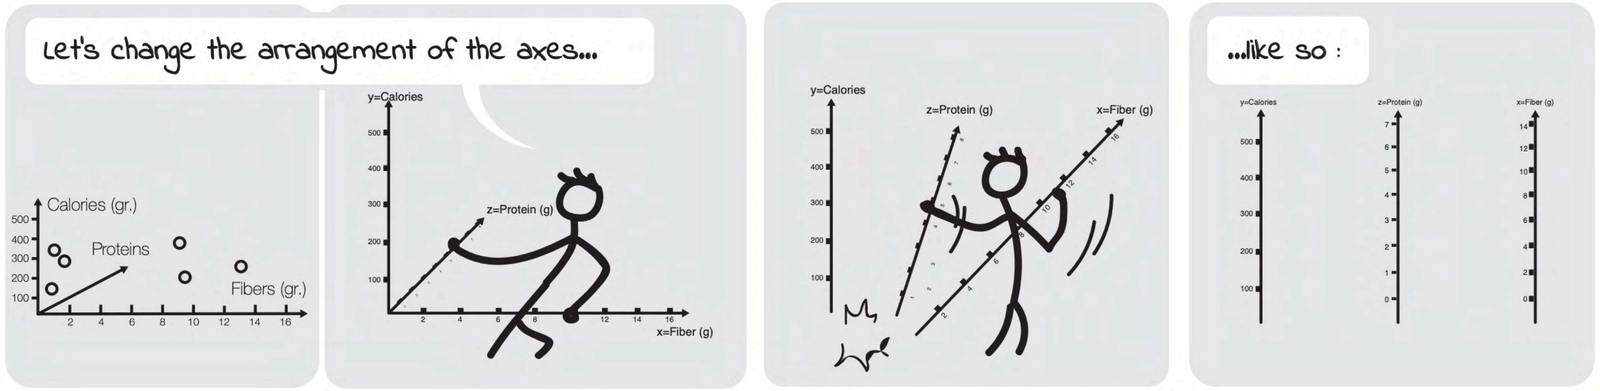
- **Einschränkungen:** Sichtbare Muster nur zwischen benachbarten Achsenpaaren
- Gängige Lösung: Sortierung der Achsen durch Interaktion

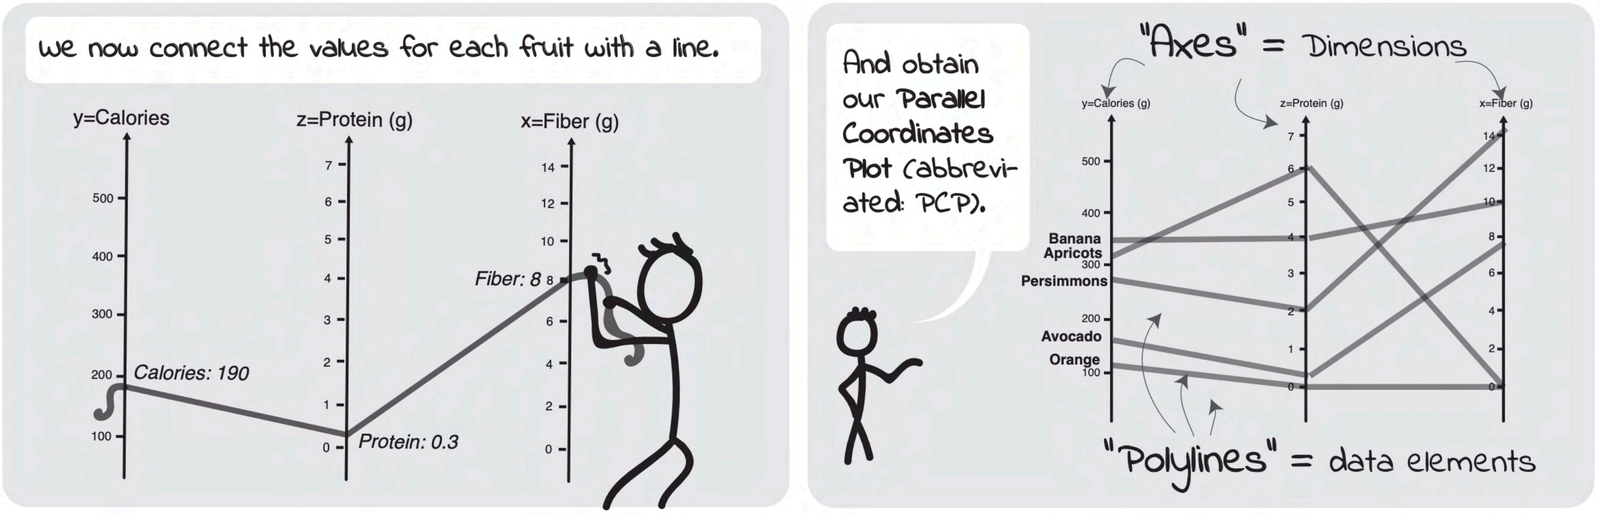
WHAT — Multivariate quantitative Daten

WHY — Vergleich von mehreren quantitativen Werten, Korrelationen analysieren



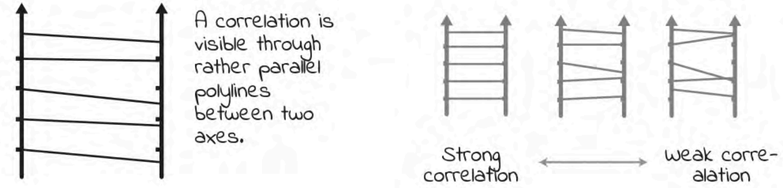
Erstellung von Parallel Coordinates



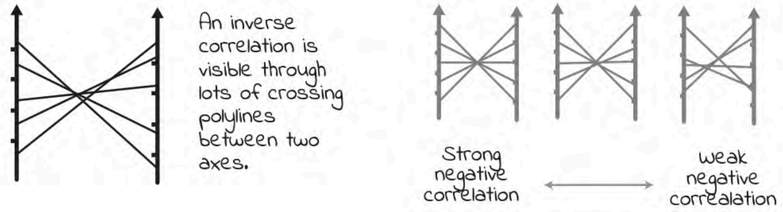


Korrelationsmuster

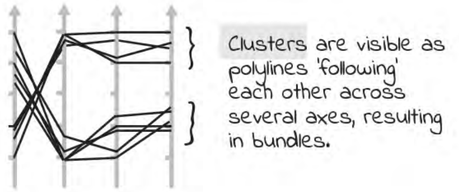
Positive Korrelation = Parallele Linien



Negative Korrelation = Kreuzende Linien



Gruppierte Linien = Cluster



PC Cheat Sheet: https://visualizationcheatsheets.github.io

Radar Chart (Spider Chart, Star Plot)

Populäre Visualisierungstechnik um mehrere quantitative Werte auf relativ kompaktem Raum darzustellen.

Datenwerte sind durch Linien oder Flächen verbunden, um die Beziehungen zwischen den verschiedenen Variablen darzustellen.





WHAT Multivariate quantitative Daten

WHY Vergleich von mehreren quantitativen Werten, Korrelationen analysieren

- alle Achsen haben die gleiche Skala
- Daten werden auf die gleiche Weise interpretiert: ein Punkt, der weiter am Rand liegt, wird als größer oder höherer Wert interpretiert

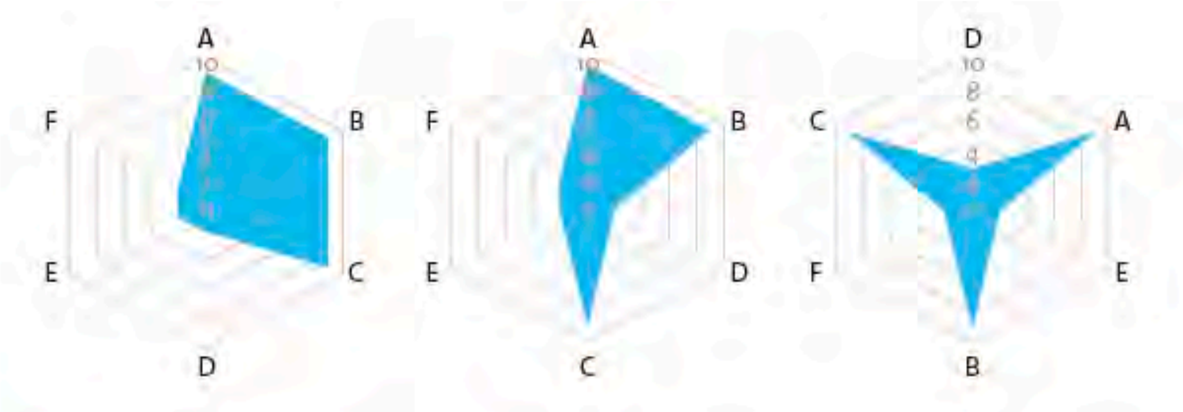
[Blois et al. 2022, Schwabish 2021]

Radar Chart (Spider Chart, Star Plot)

Folgende Faktoren sollten bei der Verwendung von Radar Charts berücksichtigt werden: [Blois et al. 2022]

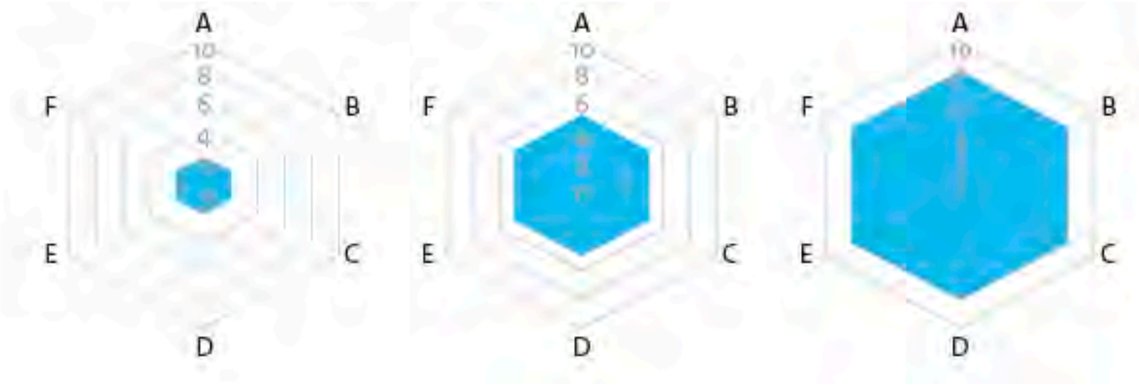
Die Form wird durch die Reihenfolge und nicht durch die Daten bestimmt

- Form, die sich ergibt, hat keinen wirklichen Bezug zur Botschaft, da sie hauptsächlich durch Reihenfolge der Achsen bestimmt wird
- mit demselben Datensatz können verschiedene Formen konstruiert werden, je nachdem wie Achsen angeordnet sind



Überschätzung der hohen Werte

- aufgrund des größeren Abstands zwischen den Achsen am Rand des Radar Charts werden größere Datenwerte überschätzt und kleinere sind schwieriger oft einzuschätzen

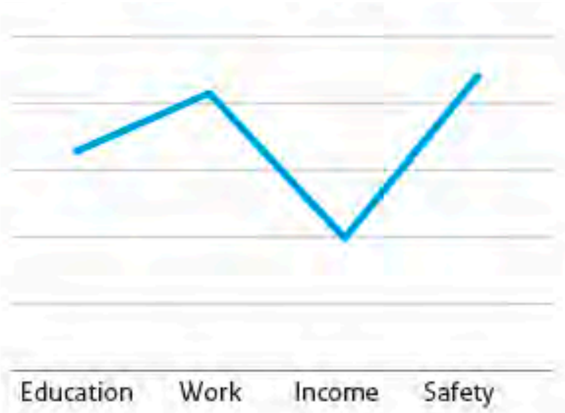


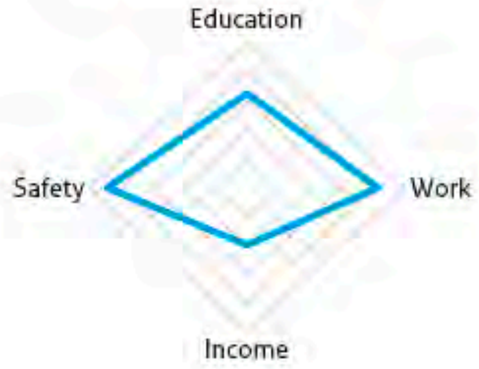
Radar Chart (Spider Chart, Star Plot)

Folgende Faktoren sollten bei der Verwendung von Radar Charts berücksichtigt werden: [Blois et al. 2022]

Unbegründete Verbindungen zwischen verschiedenen Kategorien

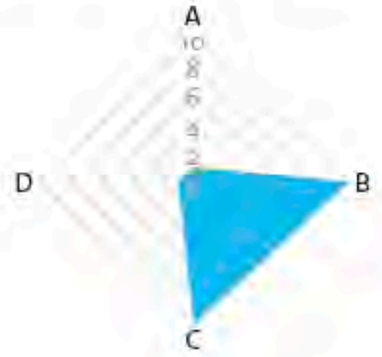
- Liniendiagramme verbinden Datenpunkte und können daher nicht zur Darstellung von Datenkategorien verwendet werden, da es keinen Übergang zwischen ihnen gibt
- Radar Charts hingegen stellen diese Verbindung her

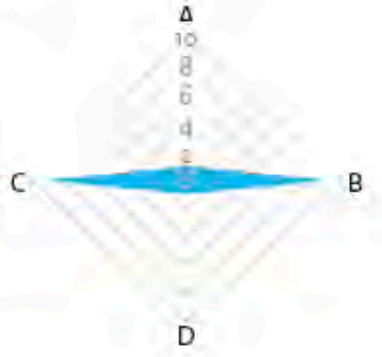




Größe der Fläche gibt nicht den Durchschnitt wieder

- farbige zweidimensionale Fläche kann irreführend sein, da sie einen Hinweis auf den Durchschnittswert zu geben scheint
- eine Schätzung auf der Grundlage der Flächengröße wäre jedoch falsch
- Beispiel: 50 % der Datenpunkte haben Höchstwert, aber Flächengröße abhängig von Achsenreihenfolge





Klassifikation von Visualisierungen

WHY



Korrelationen erkennen



Kategorien vergleichen

Verteilungen analysieren

Part of a Whole

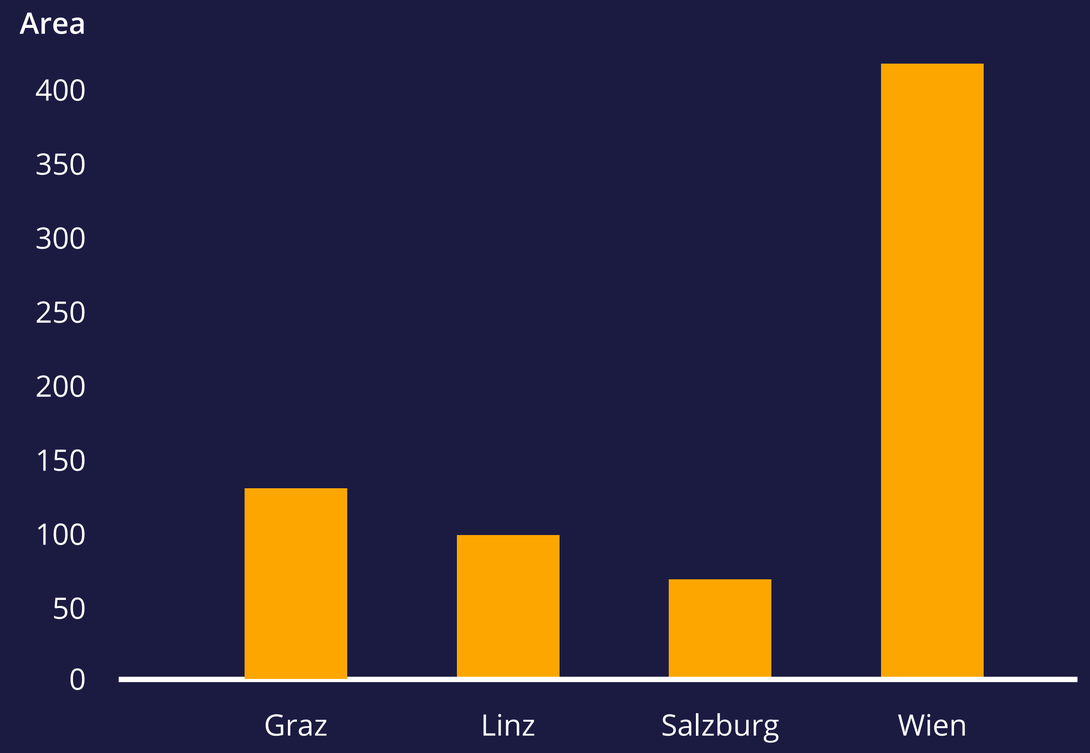
Trends erkennen



Geographische Analyse

Bar Chart (Balkendiagramm)

visualisiert **quantitative Werte** für **verschiedene Kategorien**



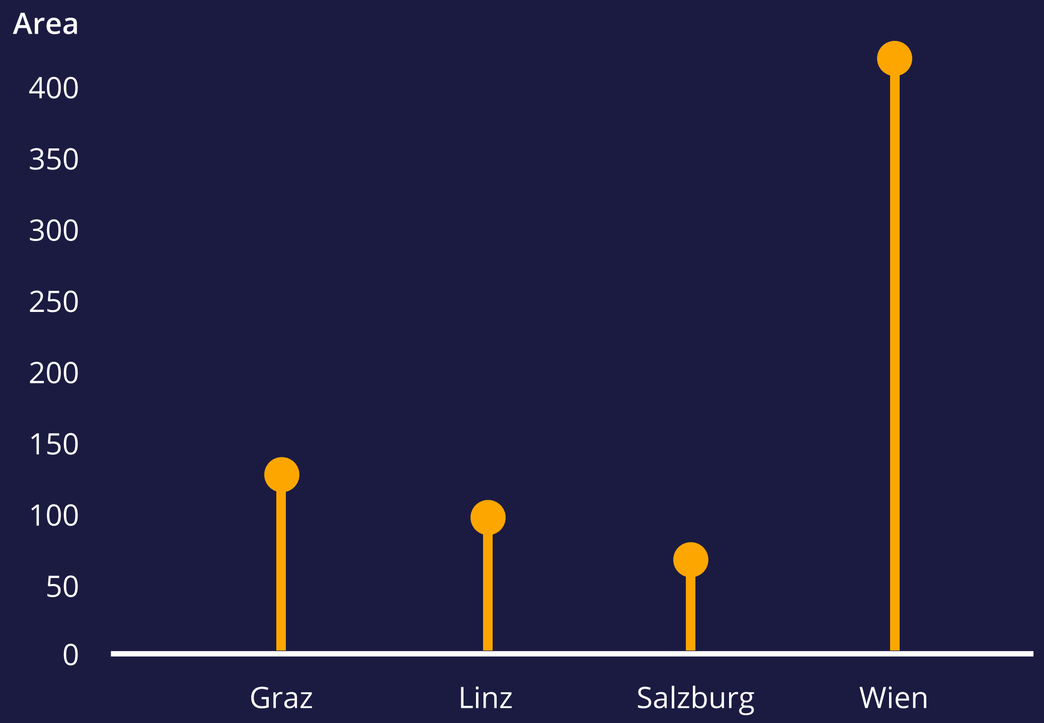
WHAT Nominale + Quantitative Daten

CITY	AREA
Graz	127
Linz	96
Salzburg	65
Wien	414

WHY Vergleichen von Werten (Comparison)

Lollipop Chart

Alternative: Lollipop Chart ersetzt Balken durch Linie und eine Form (normalerweise Punkt)

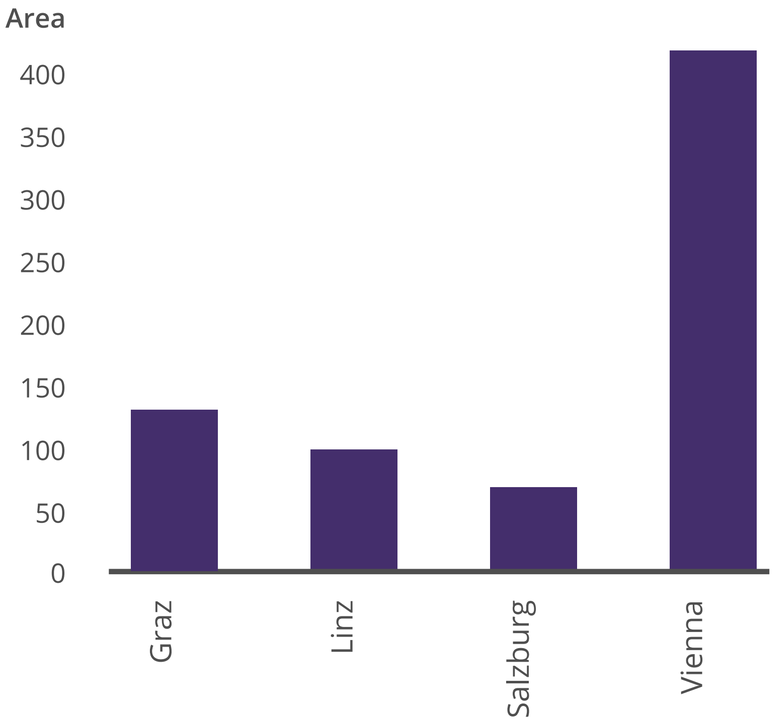


WHAT Nominale + Quantitative Daten

CITY	AREA
Graz	127
Linz	96
Salzburg	65
Wien	414

WHY Vergleichen von Werten (Comparison)

Bar Chart

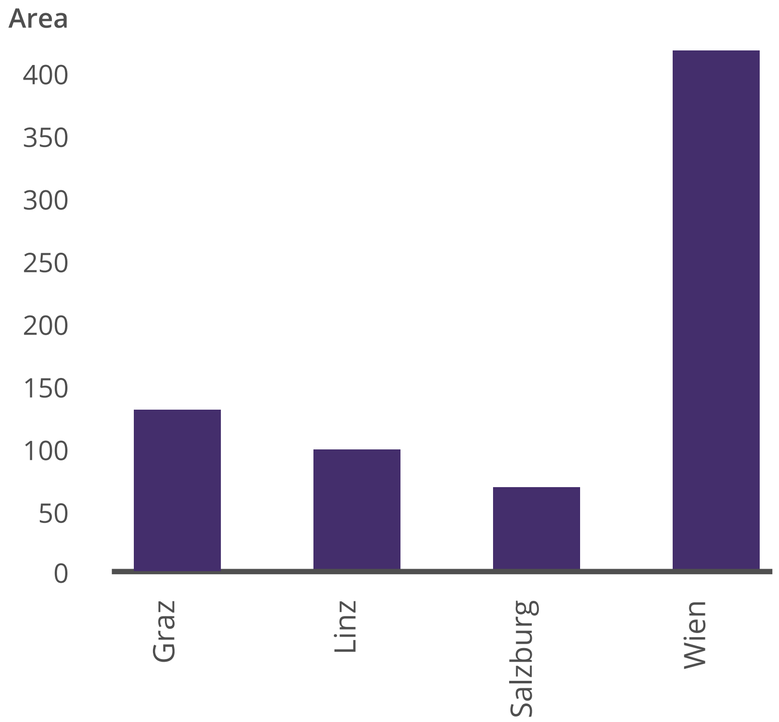


schwierig zu lesen

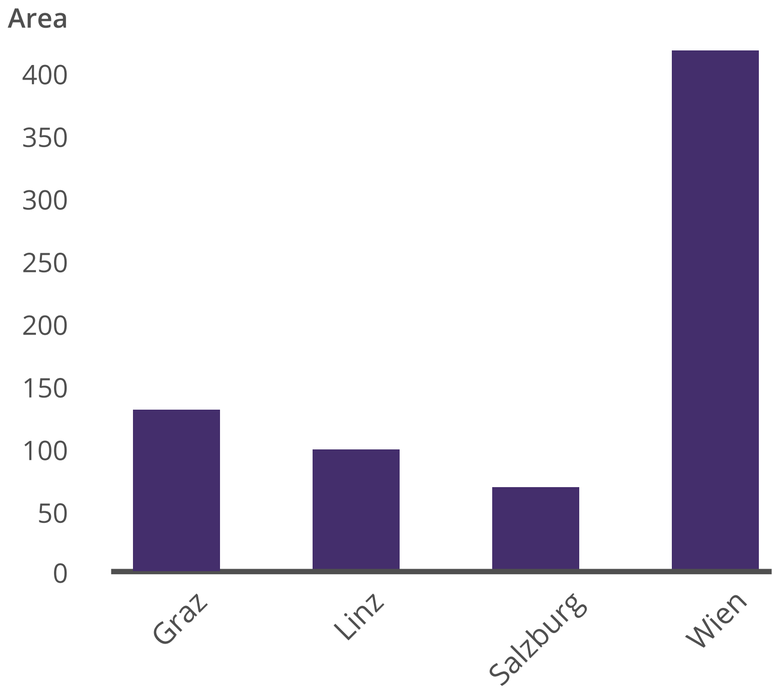


Bar Chart

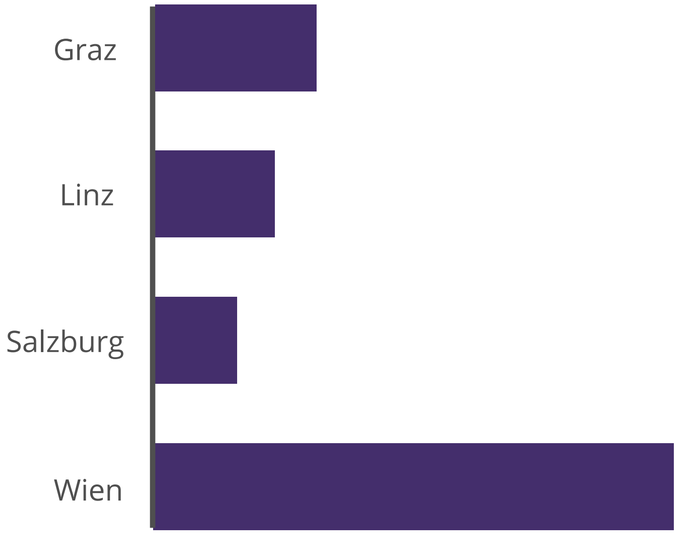
FAUSTREGEL Lange Achsenbeschriftungen sollten rotiert werden, um die Lesbarkeit zu verbessern [SCHWABISH 2021]



schwierig zu lesen



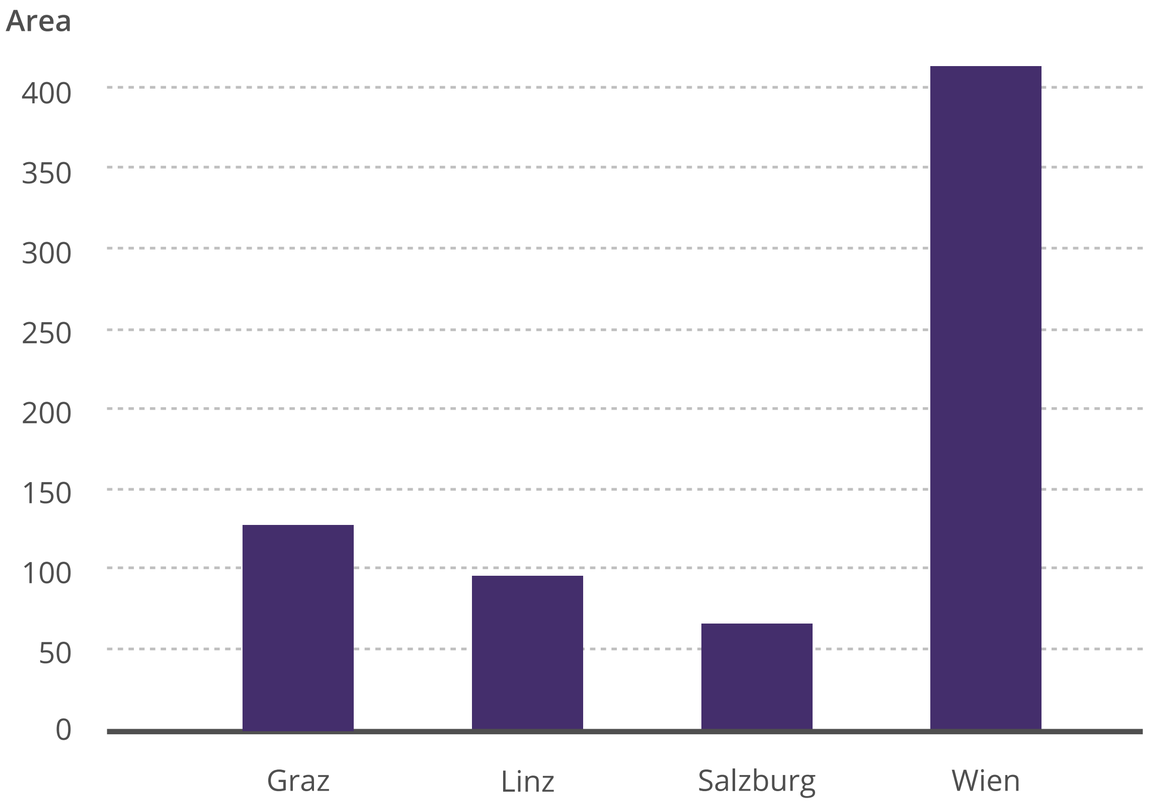
etwas besser



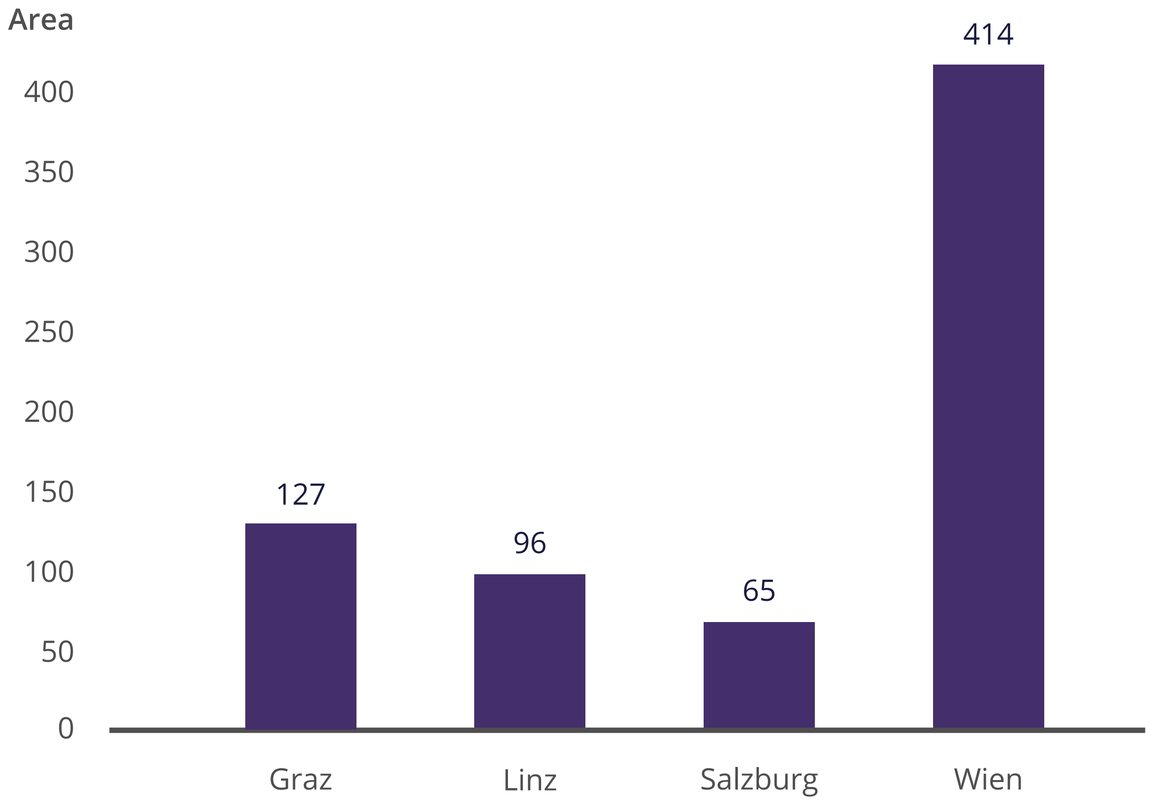
eleganteste Lösung

Raster und Labels

[SCHWABISH 2021]



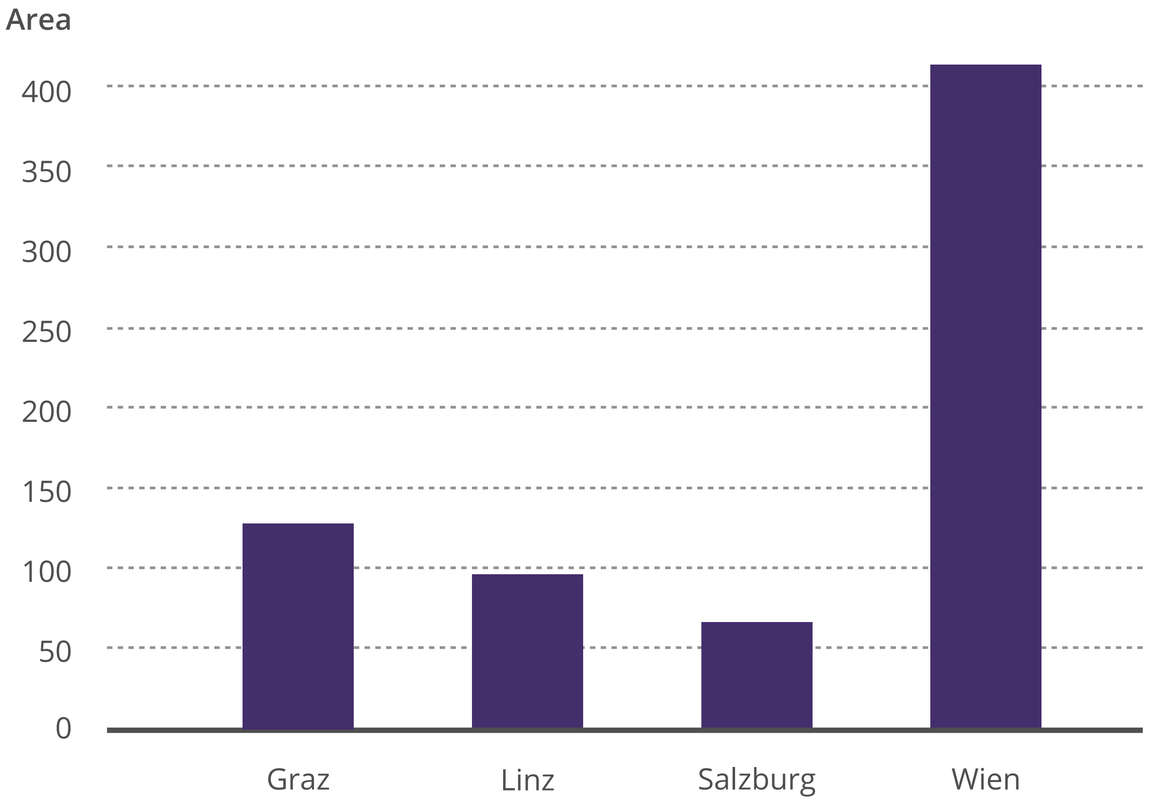
Rasterlinien unterstützen bei der Erkennung von spezifischen Werten

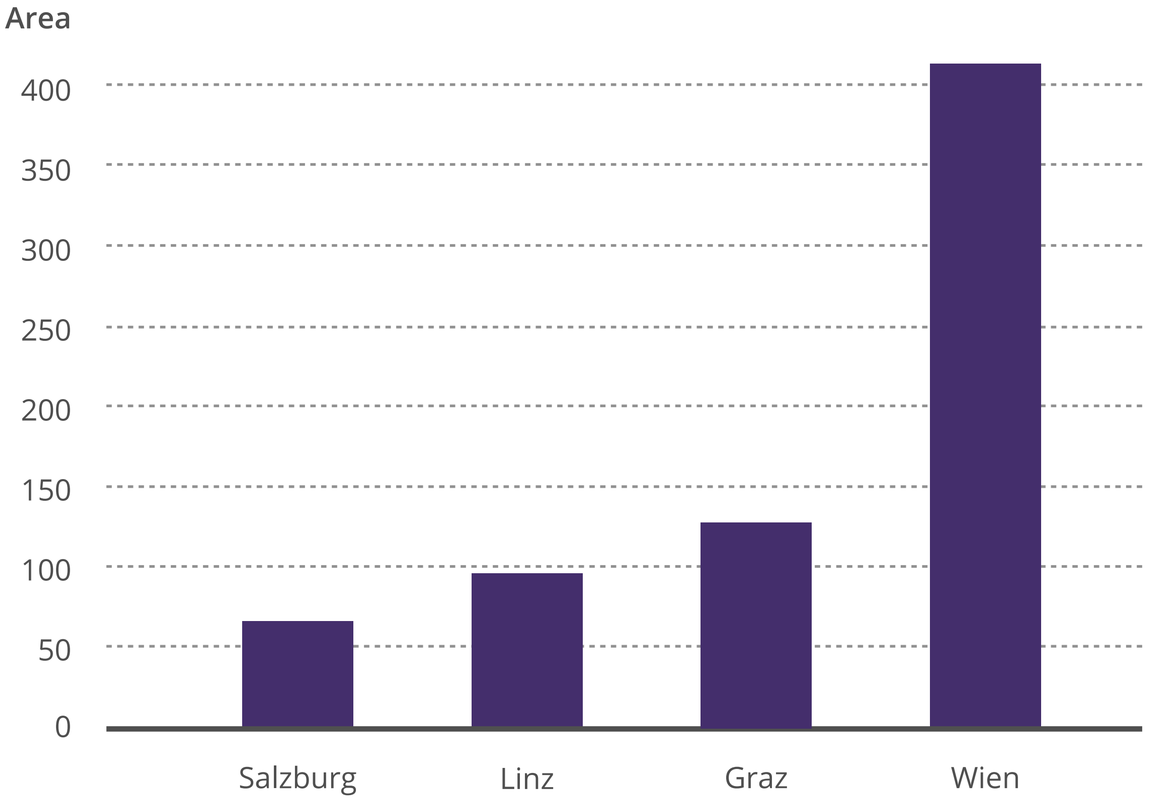


Labels machen Rasterlinien überflüssig

Bar Chart

[SCHWABISH 2021]



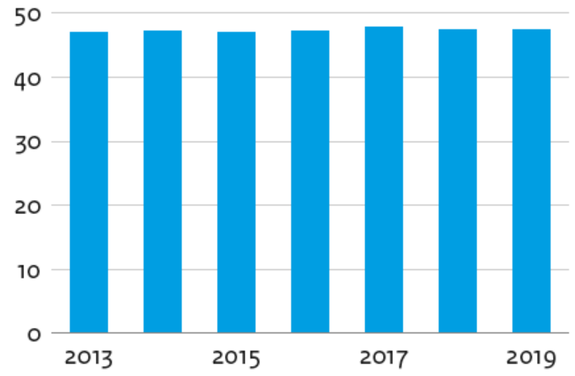


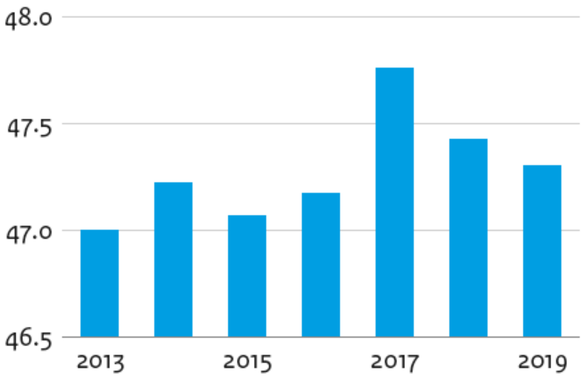
Alphabetische Ordnung: Finden des Balkens einer bestimmten Stadt wird besser unterstützt

Datengestützte Ordnung: Identifizierung der höchsten und niedrigsten Werten wird besser unterstützt

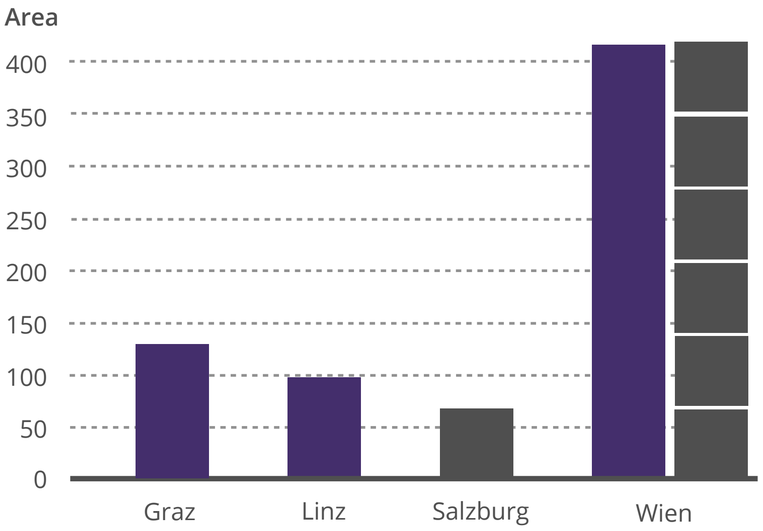
Kürzen der Achsen

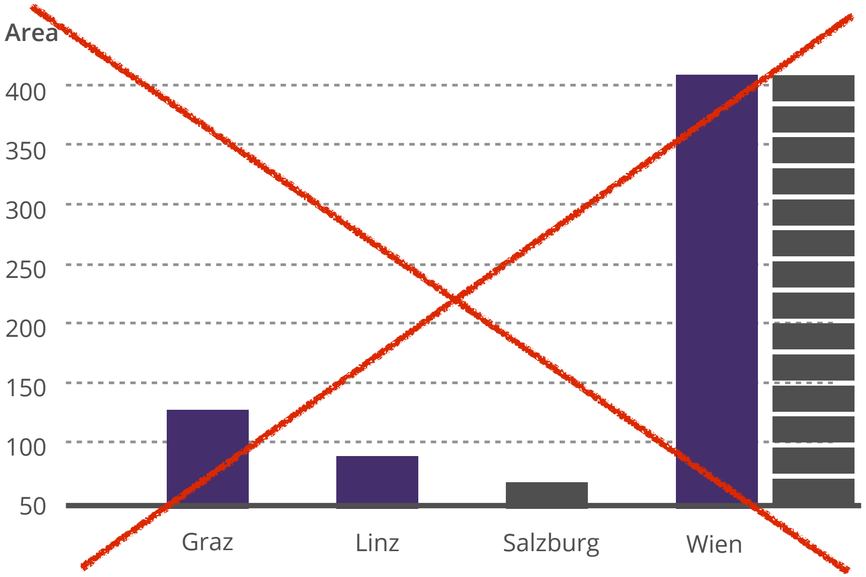
Kann eine y-Achse abgeschnitten werden oder ist es sinnvoll, sie bei 0 beginnen zu lassen?





WICHTIG! Die quantitative Achse sollte immer bei 0 anfangen!

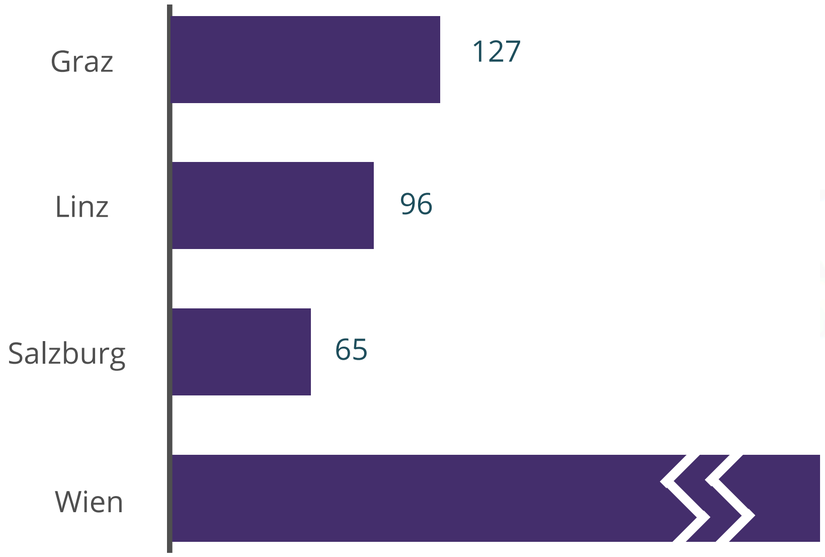


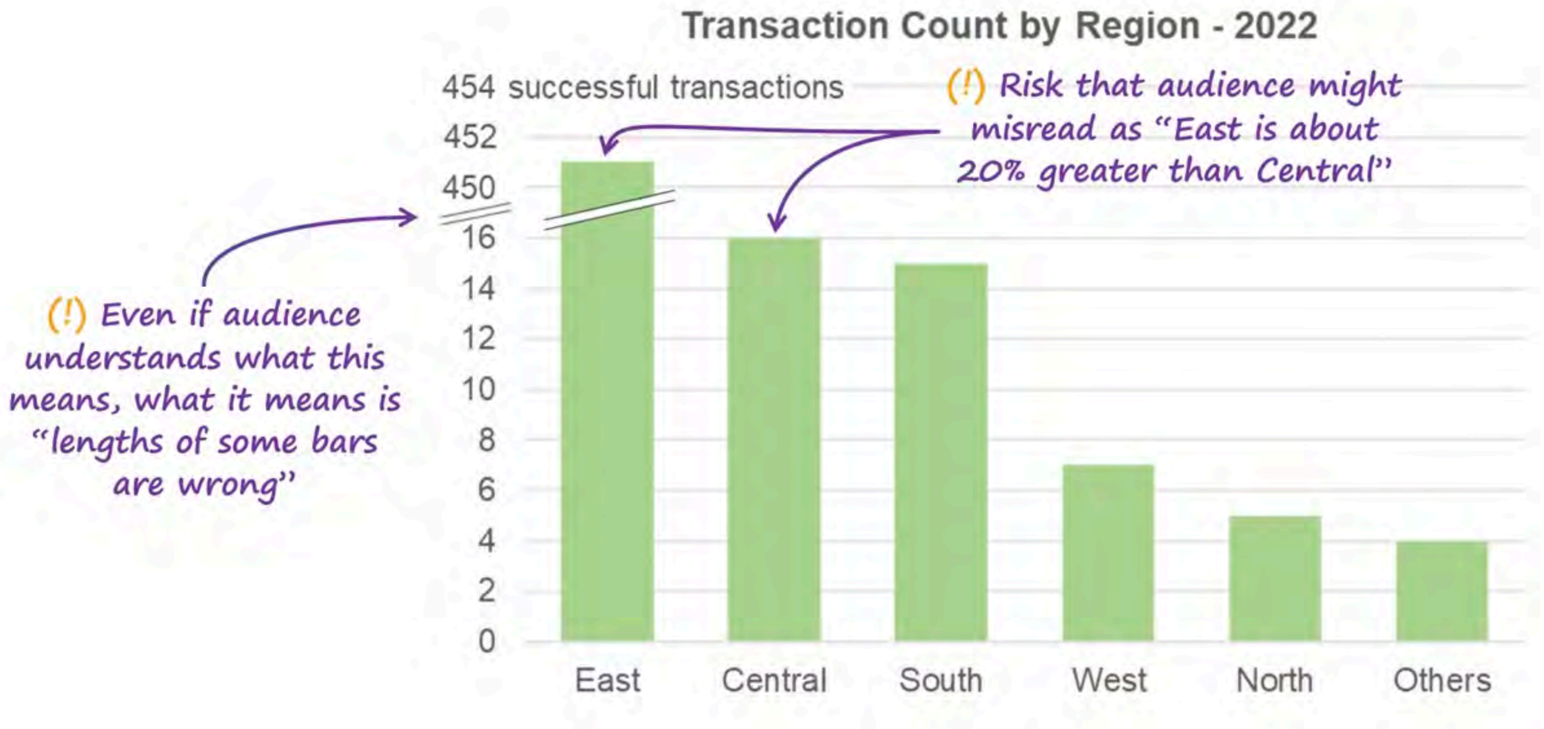


[SCHWABISH 2021, BLOIS ET AL. 2022]

Bar Chart

FAUSTREGEL Balken sollten nicht zerteilt werden, um Länge einzusparen





[SCHWABISH 2021, DESBERATS 2023]

Bar Chart-Variationen



Radialer Bar Chart (Polar Bar Chart):

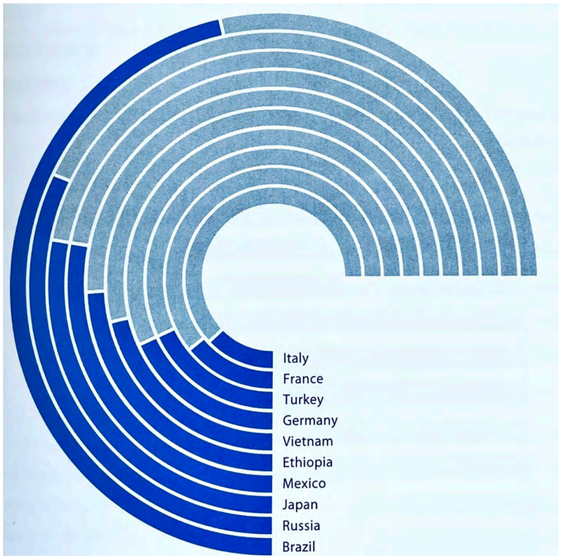
[SCHWABISH 2021]

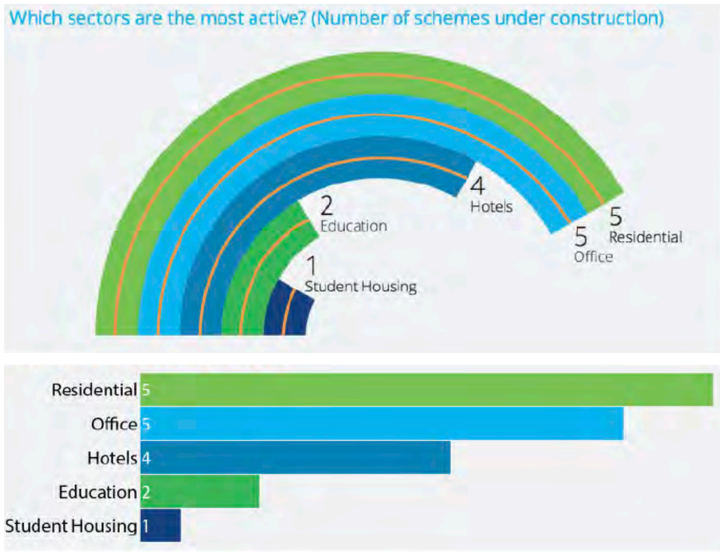
- Balken sind um einen Kreis herum angeordnet
- „Eye catching“ und nutzt den Platz bei sehr vielen Balken besser aus
- es ist schwieriger die Länge der Balken zu vergleichen und die Textbeschriftungen zu lesen



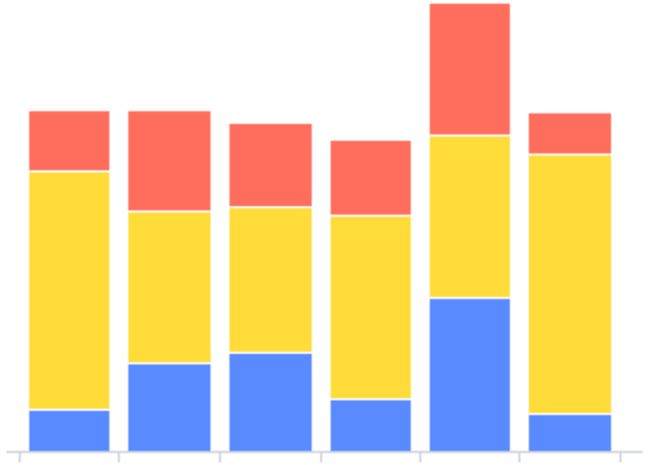
Circular Bar Chart:

- ist problematisch, weil es unsere Wahrnehmung der Daten verzerrt
- Länge der Balken entspricht nicht den tatsächlichen Werten



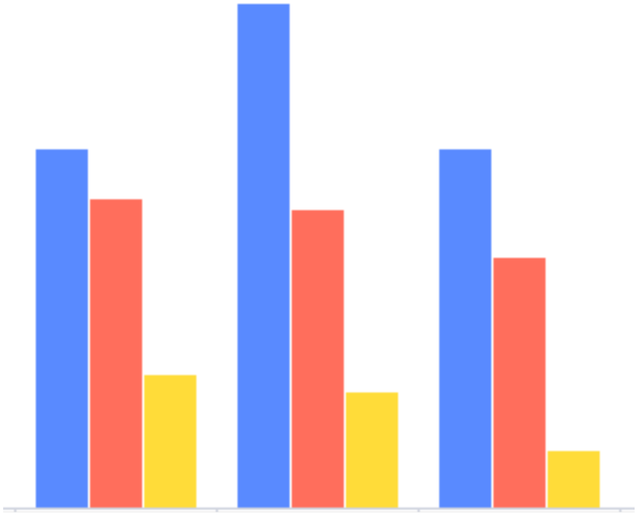


Bar Chart-Variationen



Stacked Bar Chart (Gestapeltes Balkendiagramm):

- summiert verschiedene Unterkategorien zu einer Gesamtsumme (zeigt Beziehung von Teil zu Ganzem)
- aber es ist schwieriger, die Länge von Unterkategorien zu vergleichen, weil sie nicht auf derselben Grundlinie sitzen



Grouped Bar Chart (Gruppiertes Balkendiagramm):

- zeigt zwei oder mehrere Datenwerte für jede Kategorie
- Einzelwerte können leichter verglichen werden, aber die Ermittlung der Gesamtwerte ist schwieriger

[SCHWABISH 2021]

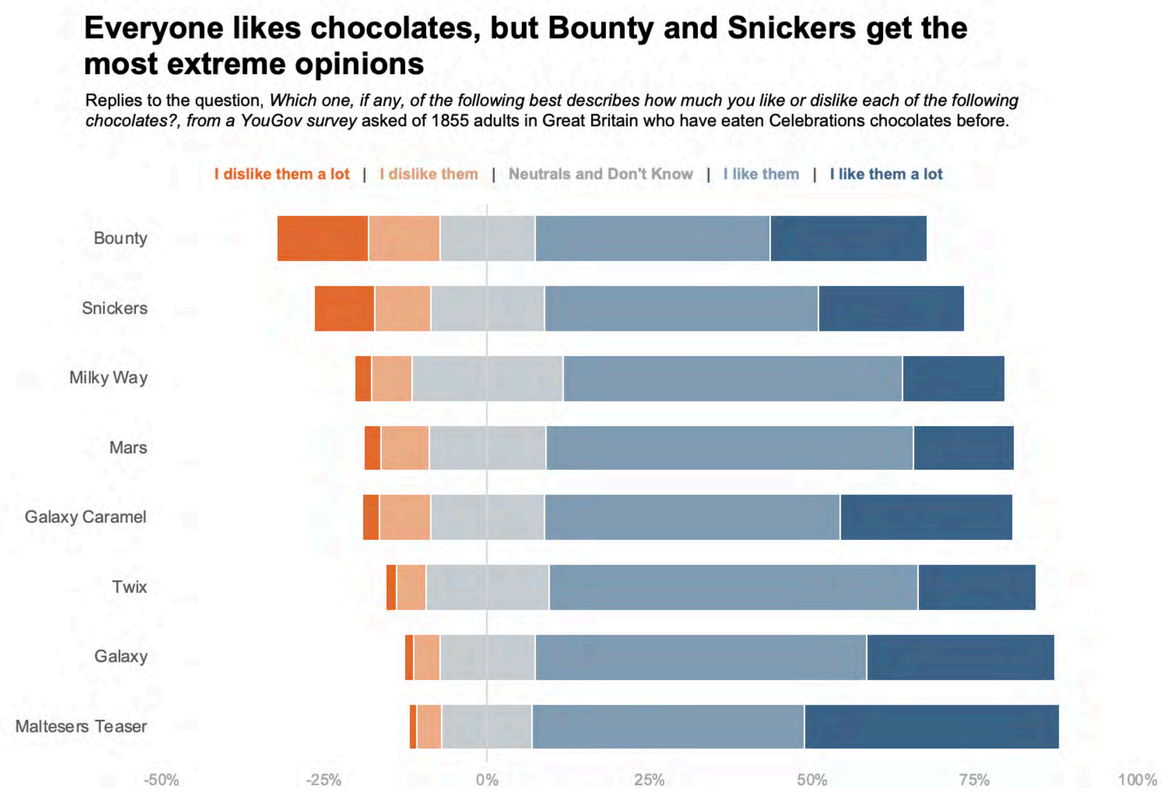
Bar Chart-Variationen

Diverging Bar Chart:

- unterstützt den Vergleich von ordinalen Kategorien
- wird hauptsächlich zur Visualisierung von Ergebnissen aus Fragebögen verwendet, in denen Likert-Skalen zum Einsatz kommen
- hebt positive, neutrale und negative Antworten hervor



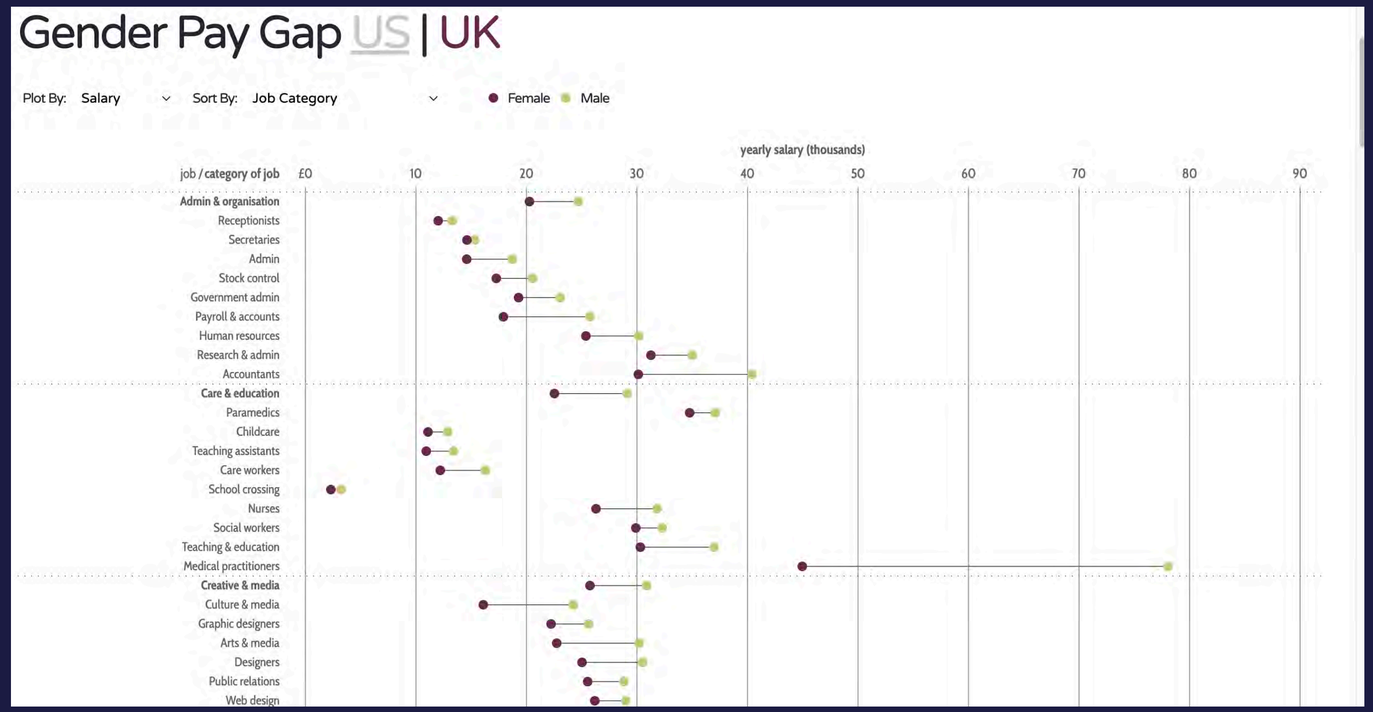
strongly disagree | disagree | neutral | agree | strongly agree



http://daydreamingnumbers.com/blog/4-ways-to-visualize-likert-scales/

Dot Plot (Connected Dot Plot, Dumbbell Chart, Gap Chart)

geeignet zum Vergleich von (vielen) Kategorien



https://www.informationisbeautiful.net/visualizations/gender-pay-gap/

WHAT nominale + quantitative Datenwert

WHY Verteilungen ansehen

- Alternative zu Stacked oder Grouped Bar Chart, besonders bei sehr vielen Balken
- Kreis entspricht Datenwert, der durch eine Linie verbunden ist

Klassifikation von Visualisierungen

WHY



Korrelationen erkennen

Kategorien vergleichen



Verteilungen analysieren

Part of a Whole

Trends erkennen



Geographische Analyse

Verteilung von Werten über einen Bereich

In dieser Tabelle mit den Gehältern der Mitarbeiter:innen ist nicht sofort ersichtlich, ob …

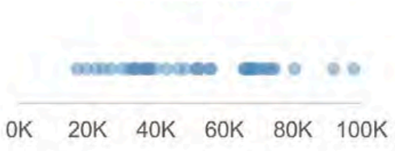
- es **Cluster** gibt (kleine Gehaltsbereiche mit vielen Mitarbeiter:innen)
- es **Lücken** gibt (Gehaltsbereiche ohne Mitarbeiter:innen)
- es **Ausreißer** gibt (Werte, die viel kleiner oder viel größer sind als die meisten anderen)

Name	Gehalt
George	17.155
Richard	48.707
Maria	40.051
Ralf	84.882
Sarah	68.552
Otto	30.426
…	…

[Desberats 2023]

Verteilung von Werten über einen Bereich

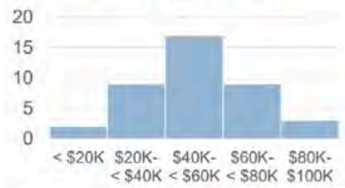
Darstellung der Verteilung eines einzelnen Wertebereichs



Strip plot



Jittered strip plot &
Bee swarm plot



Histogram

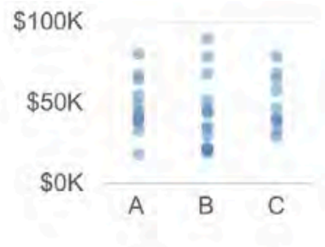


Boxplot

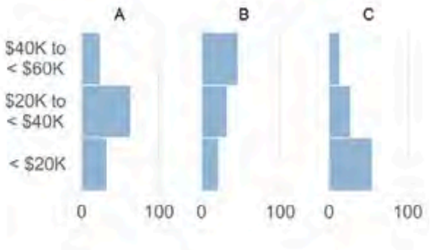


Violin Plot

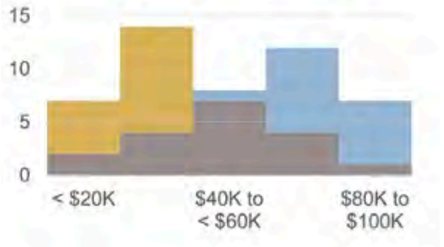
Vergleich der Verteilung mehrerer Gruppen von Werten



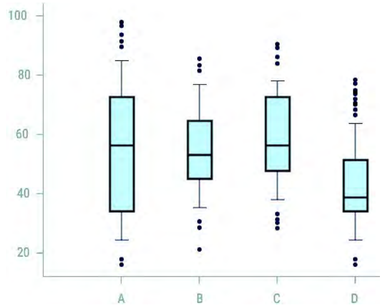
Merged strip plots



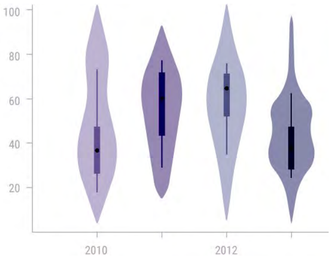
Merged
Histograms



Overlapping
Histogram



Grouped
Boxplot

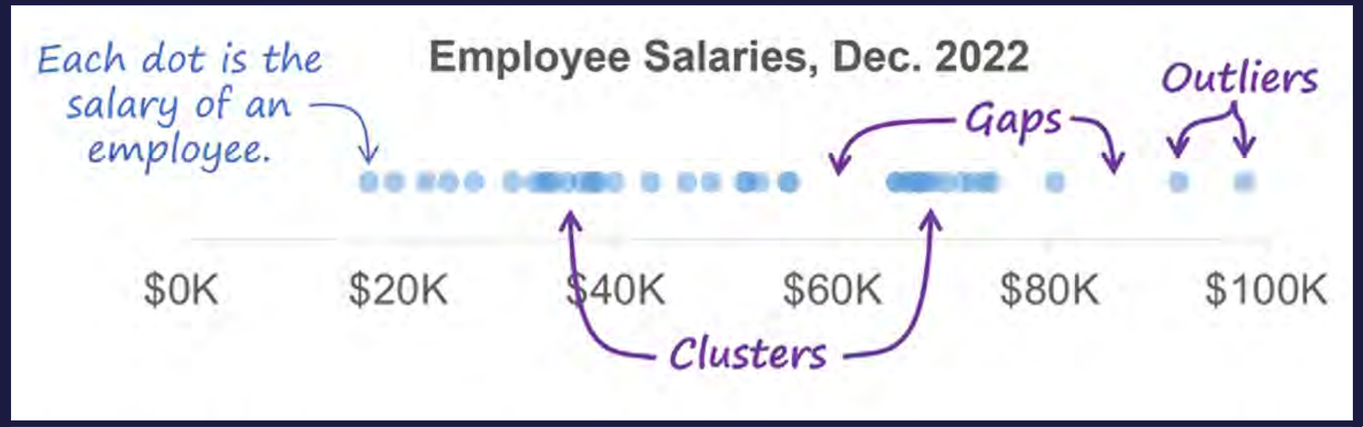


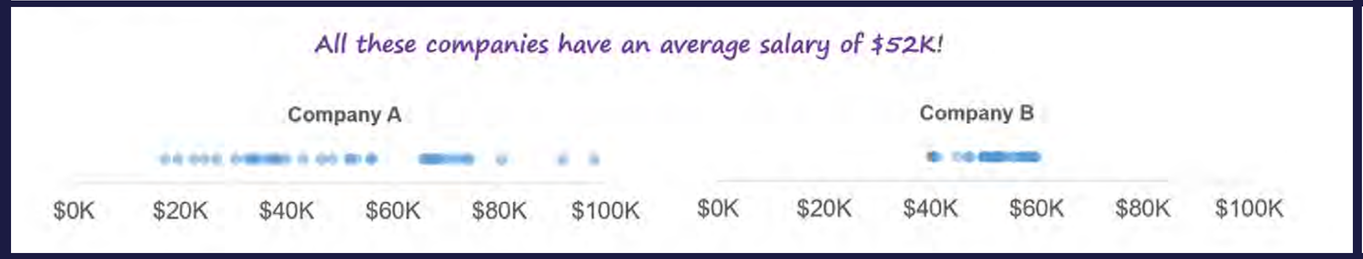
Grouped
Violin Plot

[Desberats 2023]

Strip plot

ist eine Art Scatterplot, bei der eine Variable kategorisch ist





WHAT quantitativer Wert, eine Kategorie (Schlüssel)

WHY Verteilungen zeigen

- Rule of Thumb: Punkte halbtransparent darstellen
- bei vielen Werten können sie zu nutzlosen Linien aus überlappenden Punkten werden



[Desberats 2023]

Jittered Strip plot

ein „jittered strip plot“ kann mehr Werte darstellen



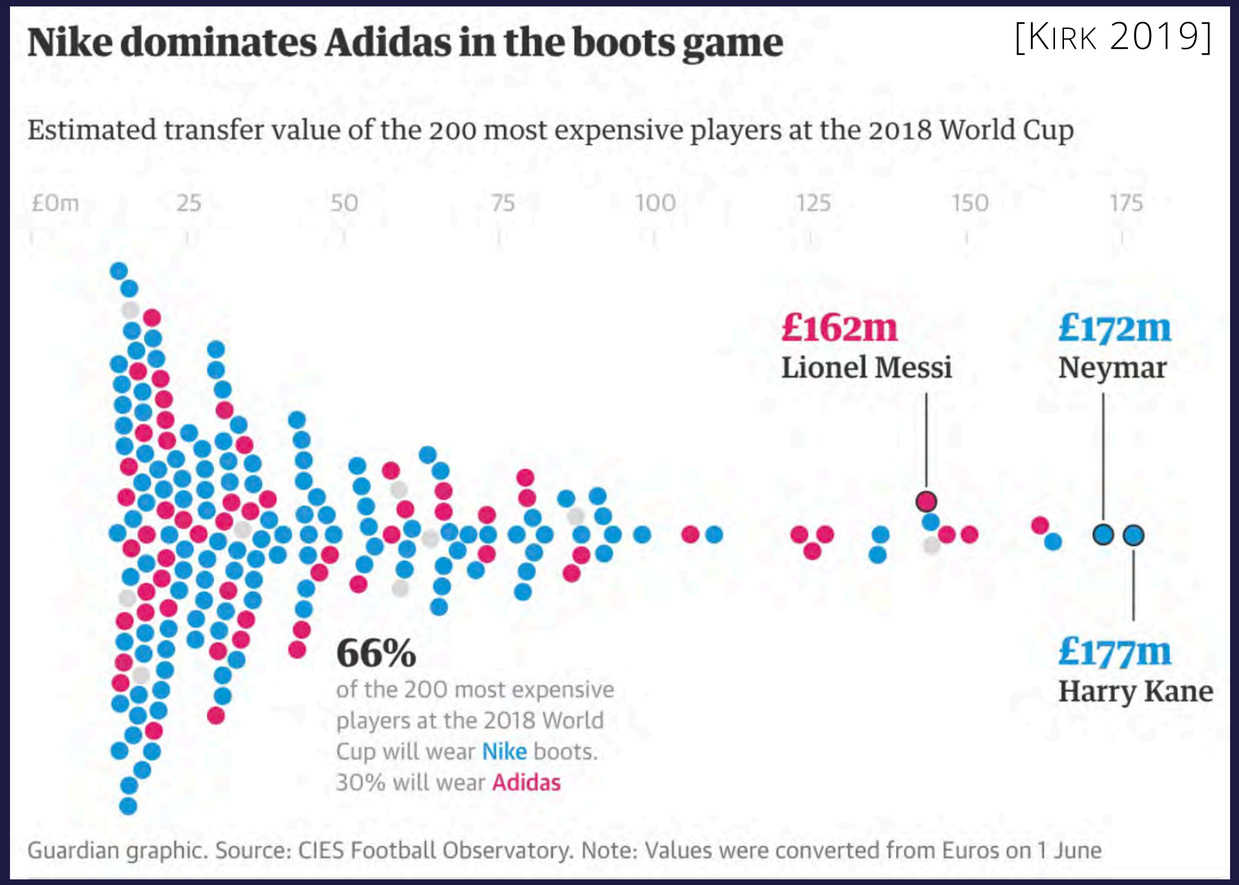
WHAT quantitativer Wert, eine Kategorie (Schlüssel)

WHY Verteilungen zeigen

- aber sie können auch zu Blöcken aus sich überlappenden Punkten werden, wenn es viele Werte gibt

[Desberats 2023]

Swarm Plot (Beeswarm Plot)



[KIRK 2019]

WHAT Quantitative (+ kategorische) Daten

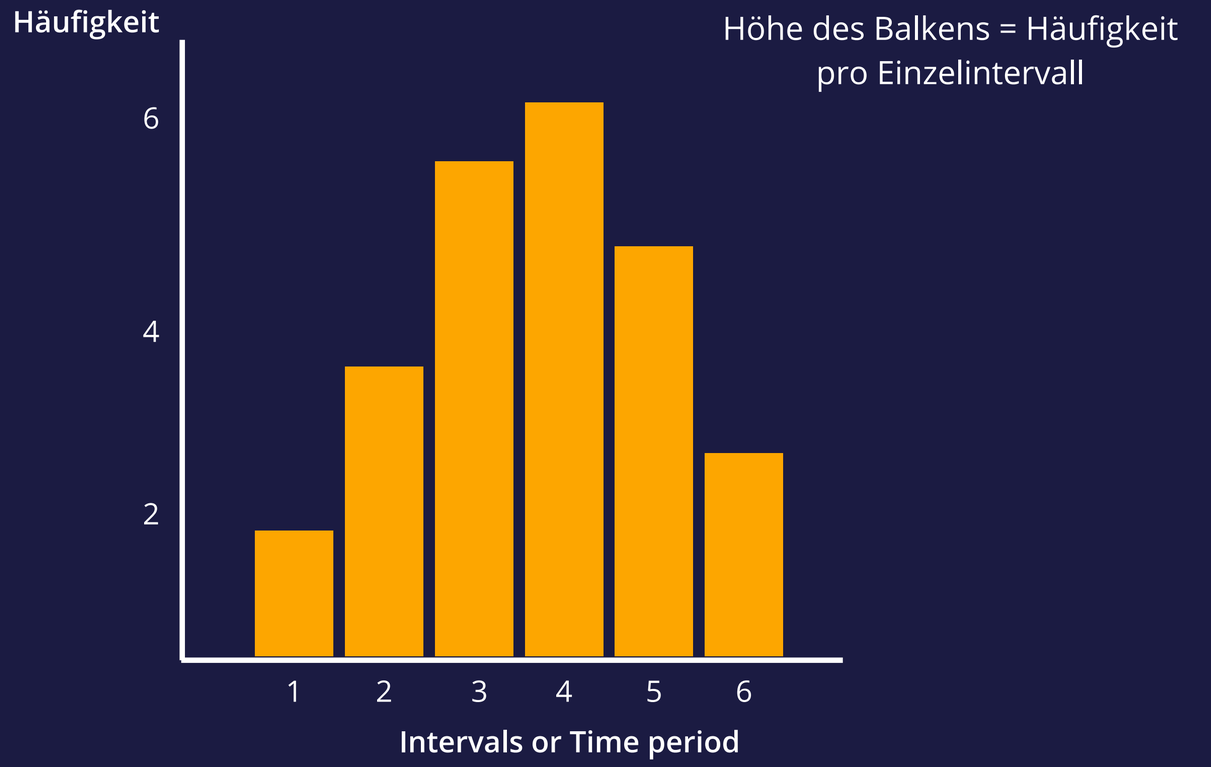
WHY Verteilungen untersuchen (Distributions)

- „verwirbelt" (jittering) alle Punkte im Datensatz, damit sie sich nicht überschneiden und jeder Punkt sichtbar ist
- verschiedene Kalkulationen können angewandt werden, um die Punkte anzuordnen (z.B. auf quadratisches oder hexagonales Raster)

[SCHWABISH 2021]

Histogramm

zeigt die Häufigkeit und Verteilung für eine qualitative Eigenschaft an



WHAT ein quantitativer Datenwert, ein abgeleitetes geordnetes Schlüsselattribut (Intervall), ein abgeleitetes quantitatives Wertattribut (Anzahl pro Intervall)

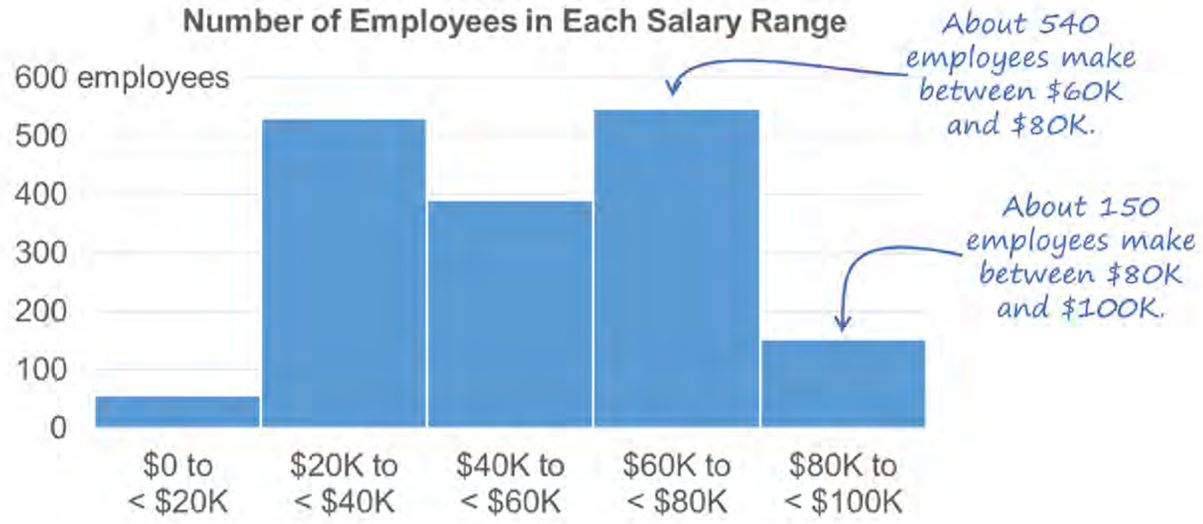
WHY Verteilungen ansehen

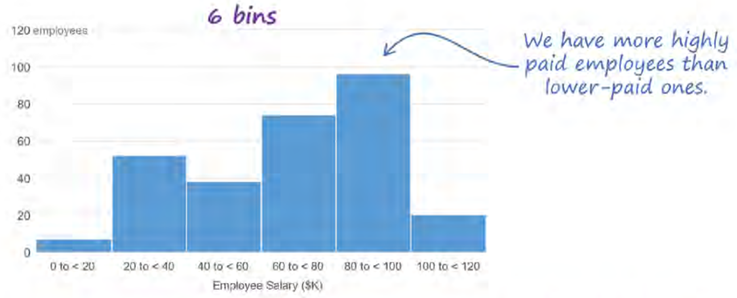
- die Anzahl der Intervalle im Histogramm kann unabhängig von der Anzahl der Elemente im Datensatz gewählt werden

Histogramm

Verwende ein Histogramm anstelle eines Strip Plots, um die Verteilung der Werte darzustellen, wenn:

1. der Datensatz viele Werte enthält
2. die Darstellung der Verteilungsstruktur wichtiger ist als die Darstellung einzelner Werte, oder
3. die vermittelnde Erkenntnis einen Vergleich der Zahlenwerte der Bins erfordert





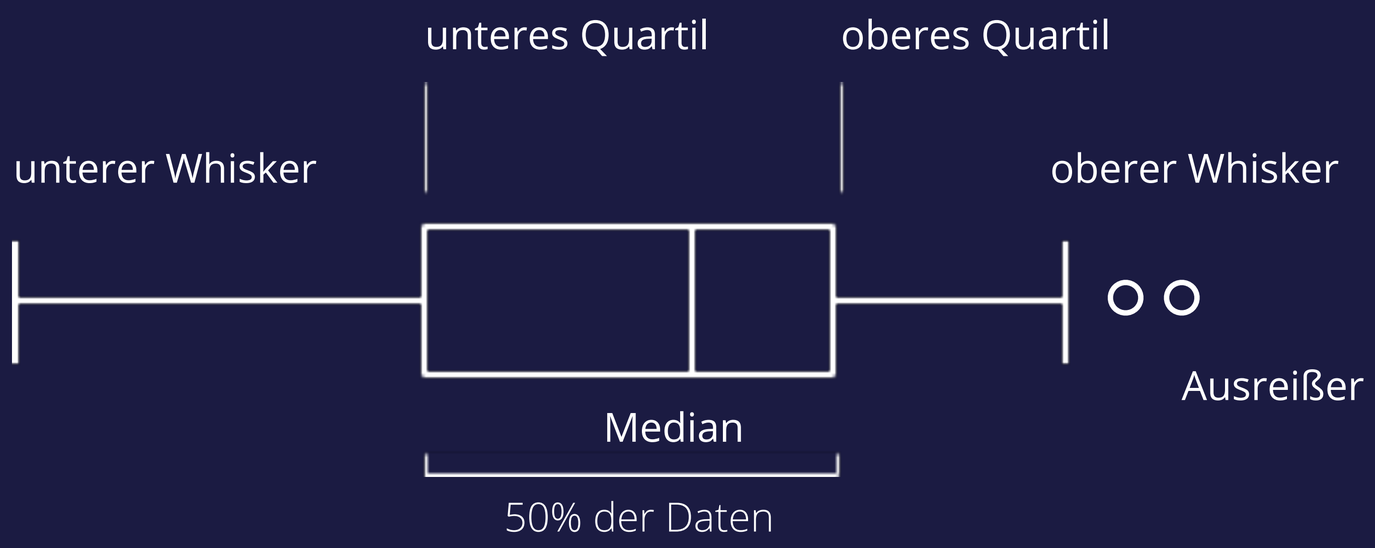




[Desberats 2023]

Boxplot (Box-and-whisker plot)

zeigt die Verteilung einer Reihe quantitativer Werte für verschiedene Kategorien



WHAT Quantitative (+ kategorische) Daten

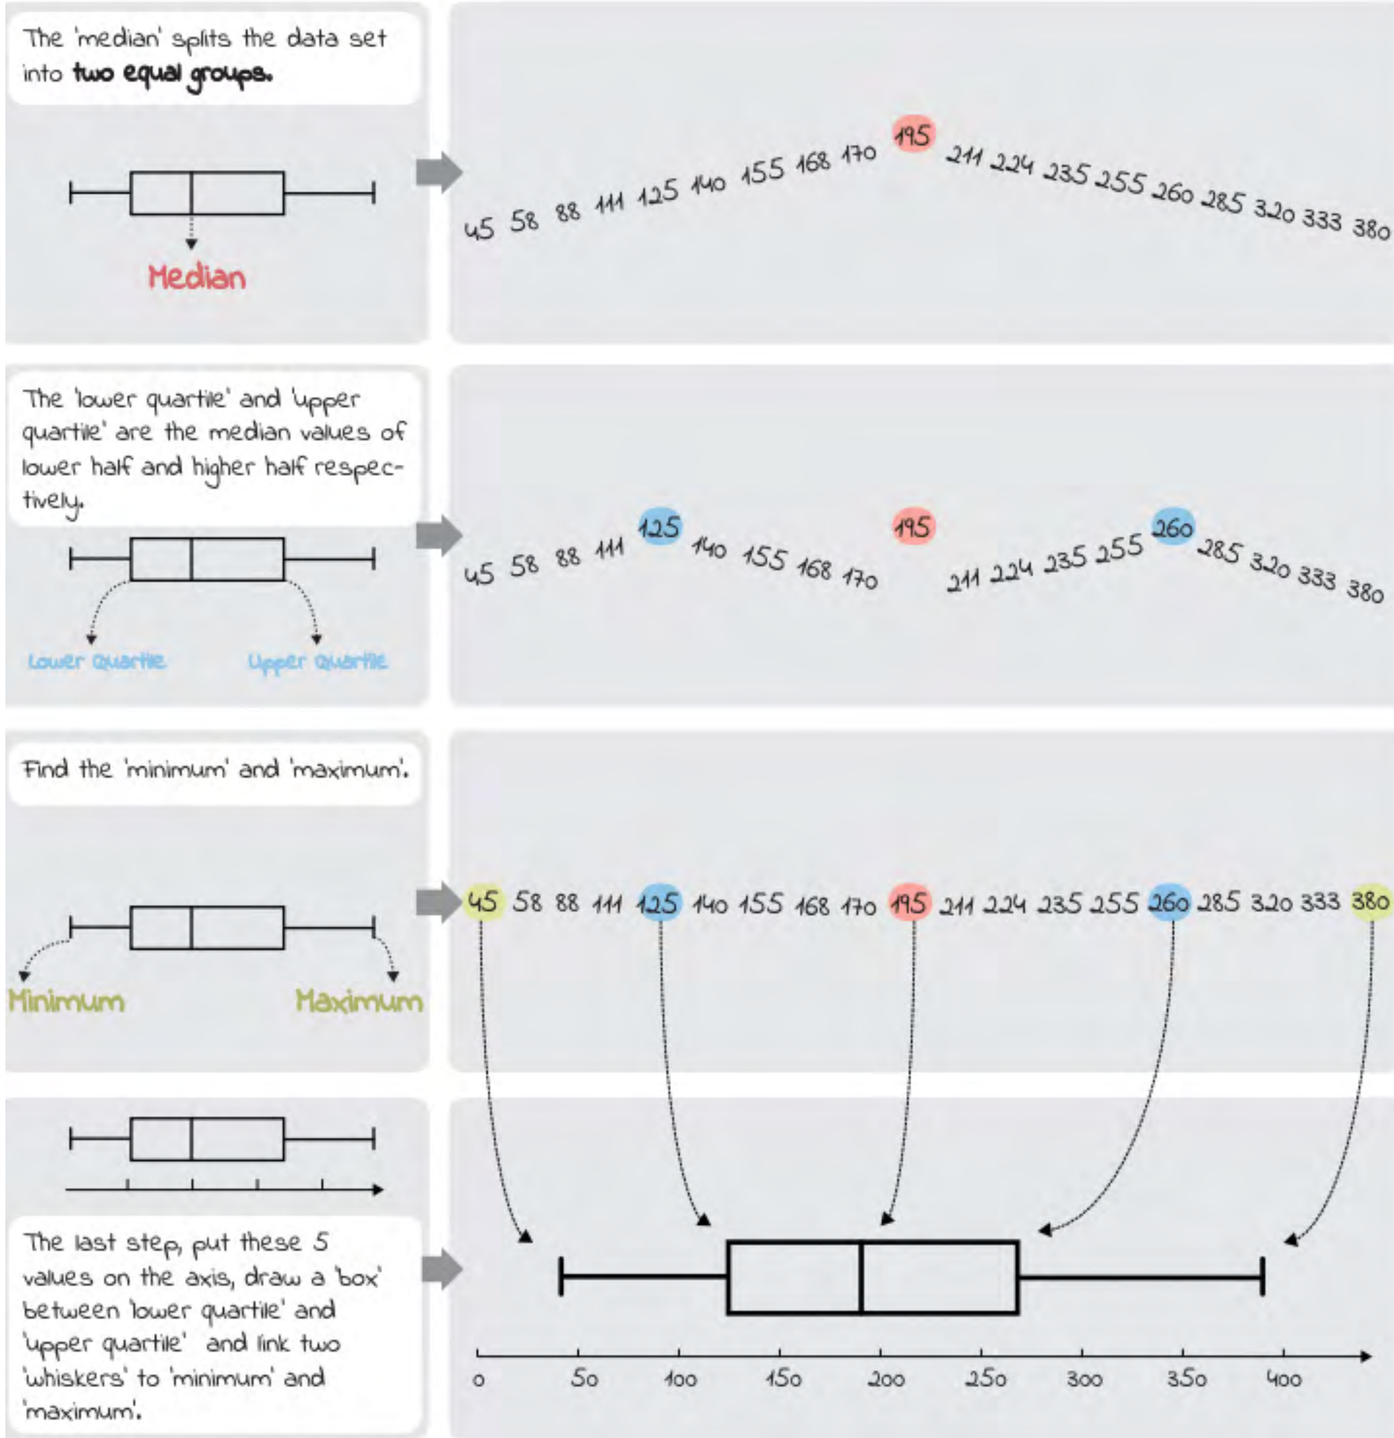
WHY Verteilungen untersuchen (Distributions)

besteht aus Kombination von Linien und Punktmarkierungen, die in der Regel fünf verschiedene statistische Maße anzeigen:

- unterer Whisker (Minimum mit/ohne Ausreißer)
- unteres (oder erstes) Quartil
- der Median (oder zweites Quartil)
- oberes (oder drittes) Quartil
- oberer Whisker (Maximum mit/ohne Ausreißer)
- optional: Ausreißer

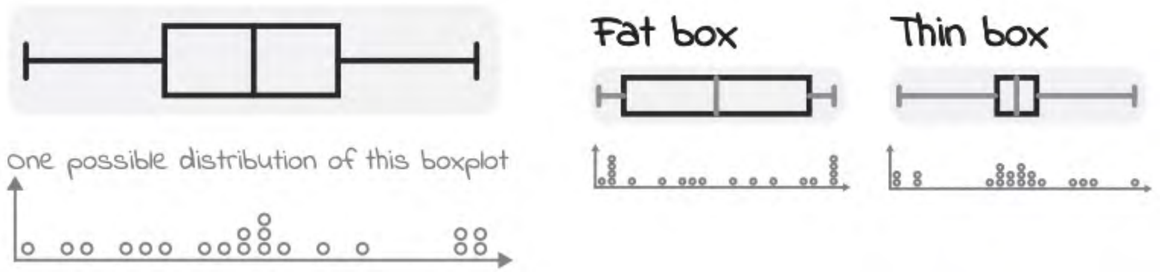
Erstellung eines Boxplots

https://visualizationcheatsheets.github.io/pdfs/boxplot_Construction.pdf



Visuelle Muster in Boxplots

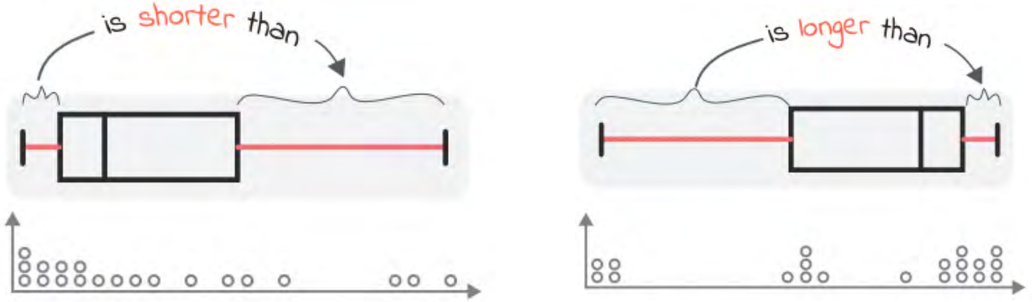
https://visualizationcheatsheets.github.io/pdfs/boxplot_visualpatterns.pdf



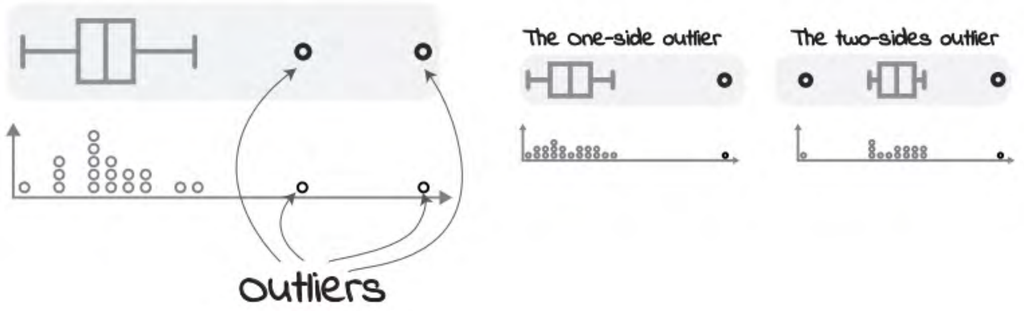
Ausgeglichen: Wenn das Boxplot symmetrisch aussieht, ist die Verteilung normal, es gibt nur wenige außergewöhnlich große oder kleine Werte.



Überschneidung: wenn 25% Prozent der Werte zwischen dem unteren Quartil bzw. Minimum und dem Median gleich sind



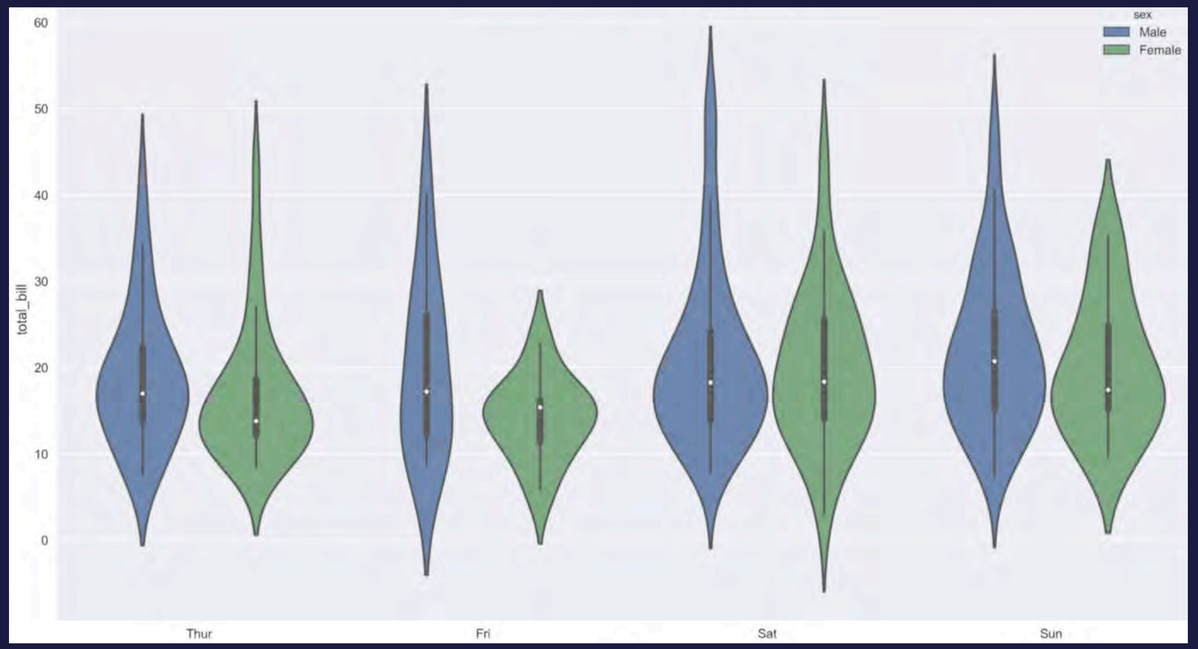
Schiefe Verteilung: Wenn einer der beiden Whisker länger ist als der andere.



Ausreißer: Datenpunkte außerhalb der Whisker

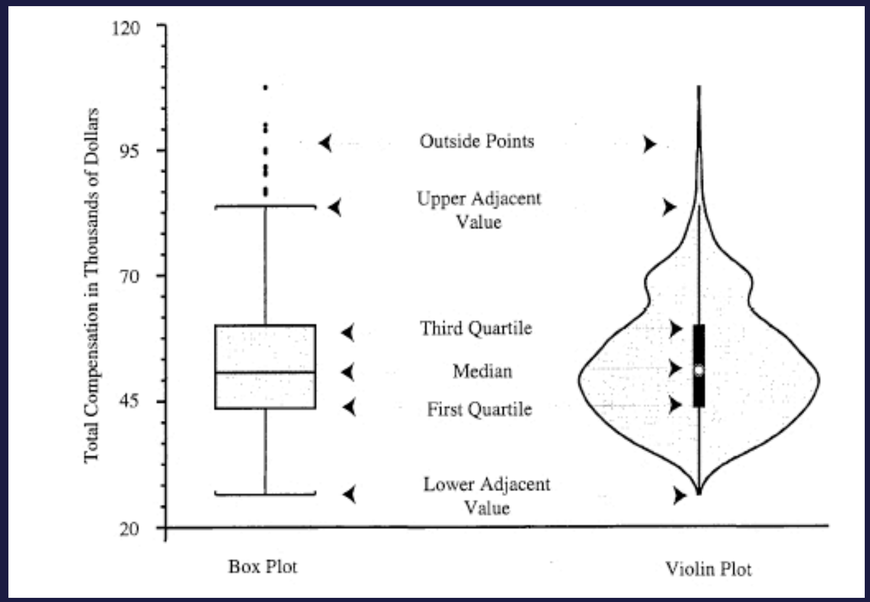
Violin Plot

zeigt die gesamte Verteilung und Form einer Reihe quantitativer Werte für verschiedene Kategorien, dickeren Bereiche bedeuten, dass es in diesem Abschnitt mehr Werte gibt als in dünneren



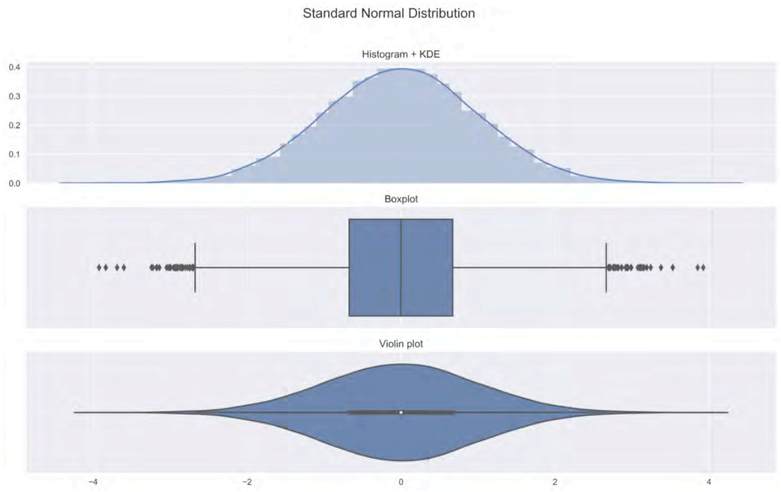
WHAT Quantitative (+ kategorische) Daten

WHY Verteilungen untersuchen (Distributions)



Vergleich (Box-and-whisker plot, Violin Plot, Histogram)

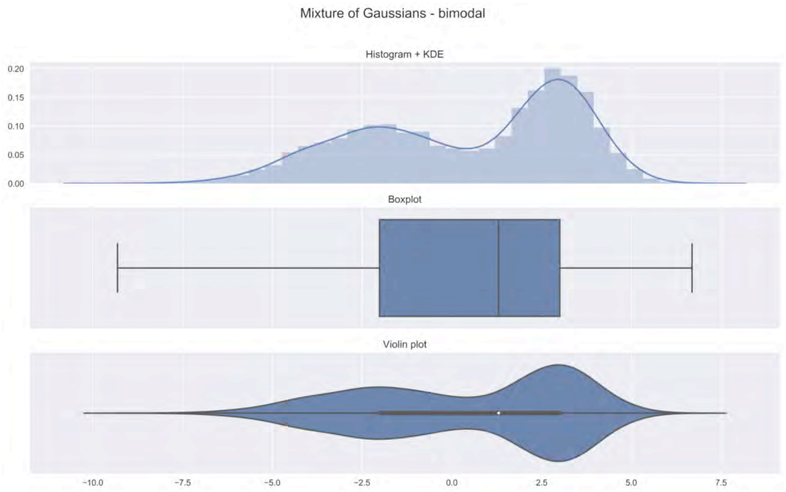
- im Gegensatz zum Box-and-Whisker Plot, bei dem bestimmte Punkte in der Verteilung ausgewählt werden, oder zum Histogramm, bei dem die Werte in Intervalle gruppiert werden, zeigt der Violin Plot die Form der gesamten Verteilung



Standard-Normalverteilung



Log-Normalverteilung



Mischverteilung

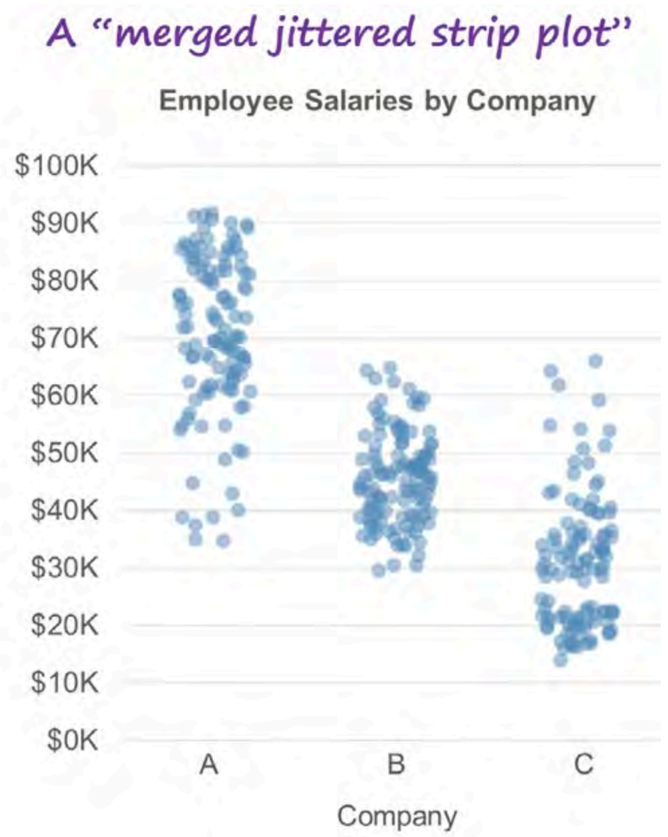
https://towardsdatascience.com/violin-plots-explained-fb1d115e023d

Vergleich der Verteilung mehrerer Gruppen von Werten

„Merged strip plots“ und „merged jittered strip plots“:

- Merged (jittered) Strip plots sind gut geeignet, wenn es wichtig ist, einzelne Werte (Lücken, Ausreißer, Cluster usw.) darzustellen



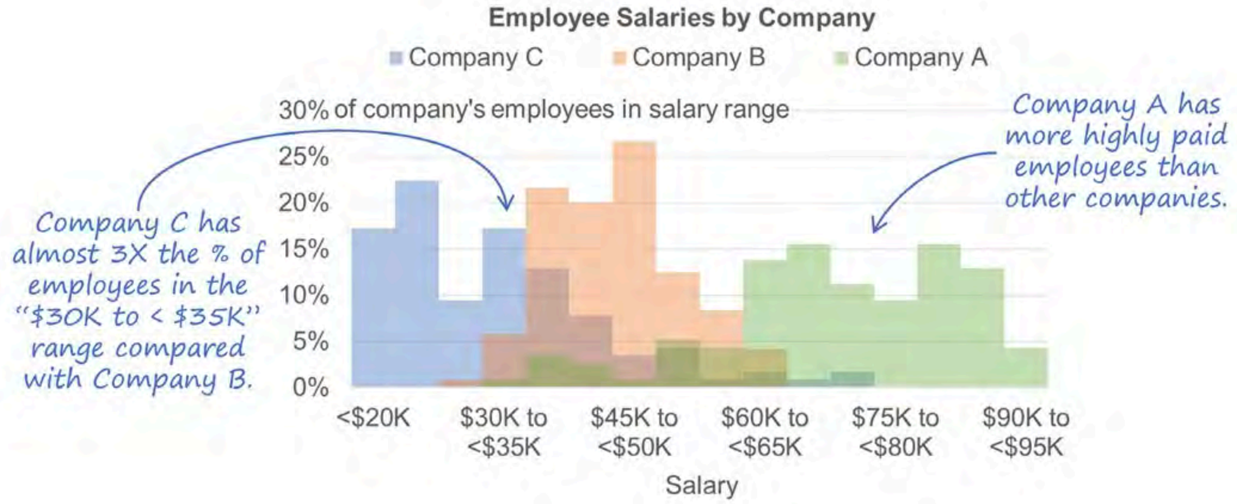


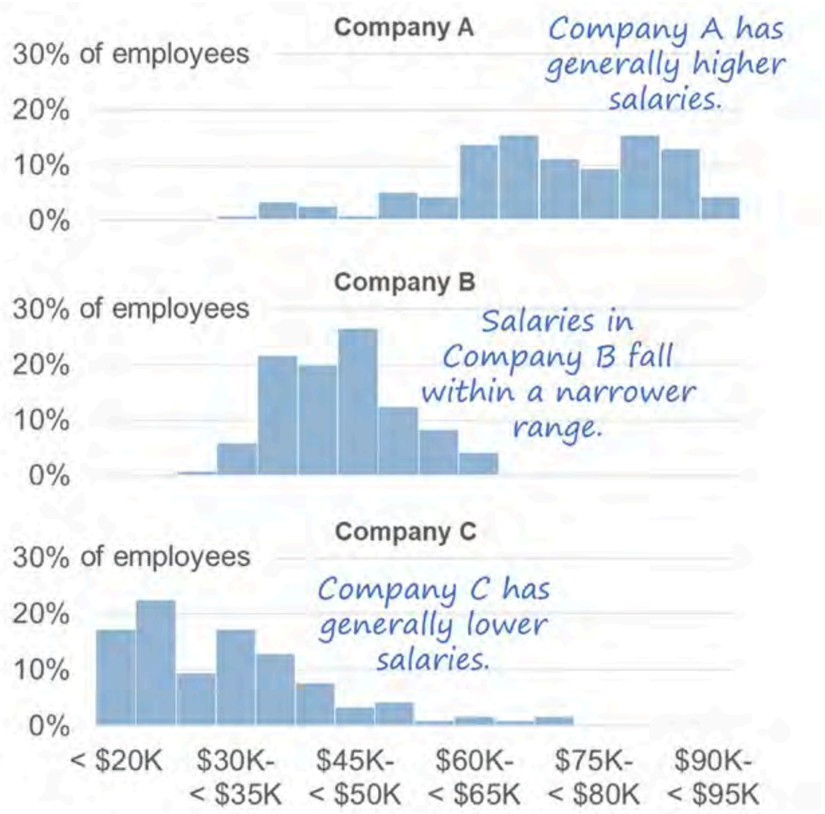
[Desberats 2023]

Vergleich der Verteilung mehrerer Gruppen von Werten

Merged Histograms und Overlapping Histograms:

- Merged Histograms funktionieren, aber es ist etwas schwierig, die Balkenhöhen zwischen den Histogrammen (z.B. zwischen den verschiedenen Unternehmen) zu vergleichen, da sie jeweils in separaten Diagrammen dargestellt sind
- Overlapping Histograms ermöglichen es, die Balkenlängen verschiedener Histogramme genauer zu vergleichen

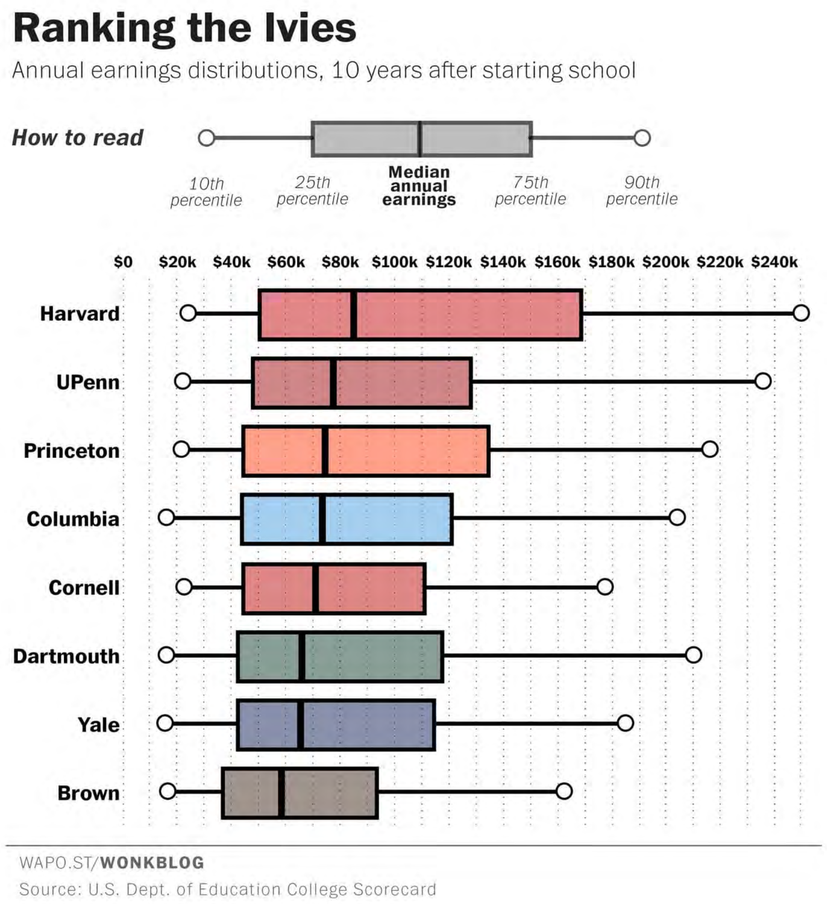




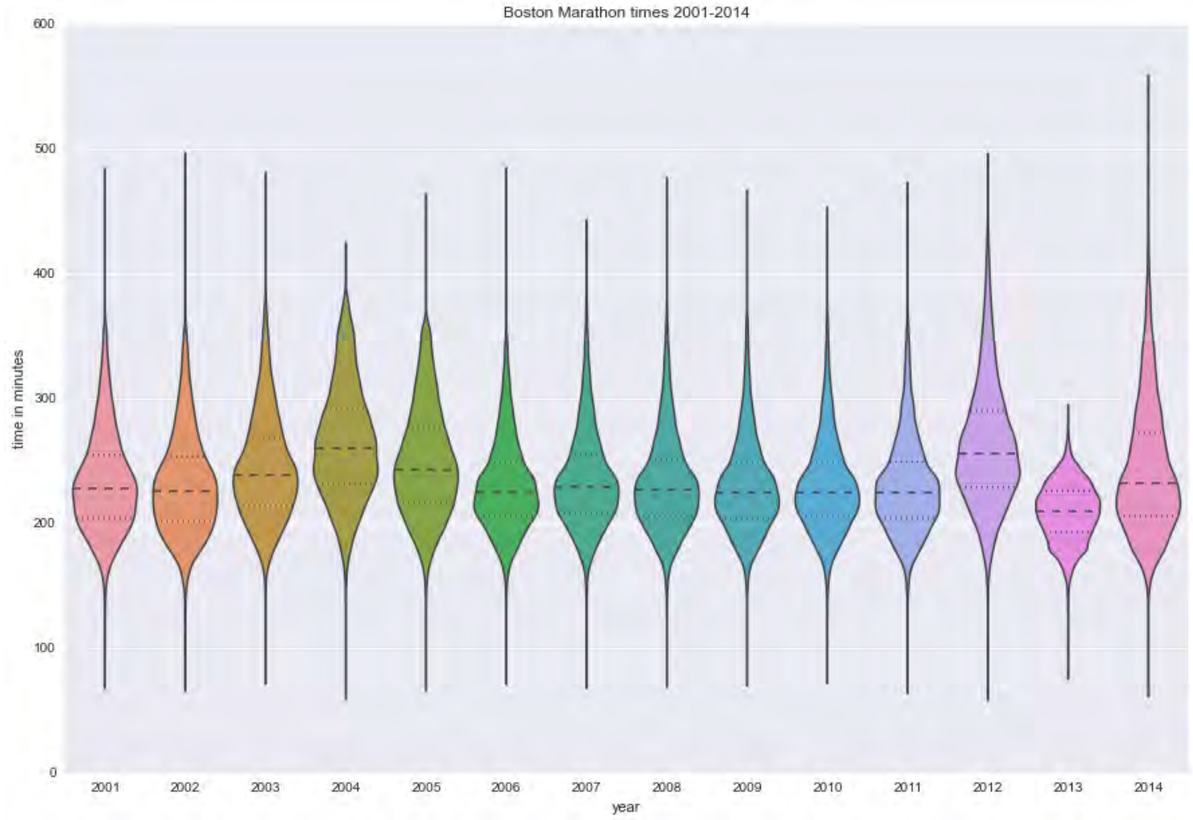
[Desberats 2023]

Vergleich der Verteilung mehrerer Gruppen von Werten

Box plots



Violin plots



Nützliche Ergänzungen für Distribution Charts

Mean oder Median darstellen

- bei der Präsentation von verteilungsbezogenen Informationen ist es oft sinnvoll, Mediane (oder seltener Mittelwerte) visuell darzustellen

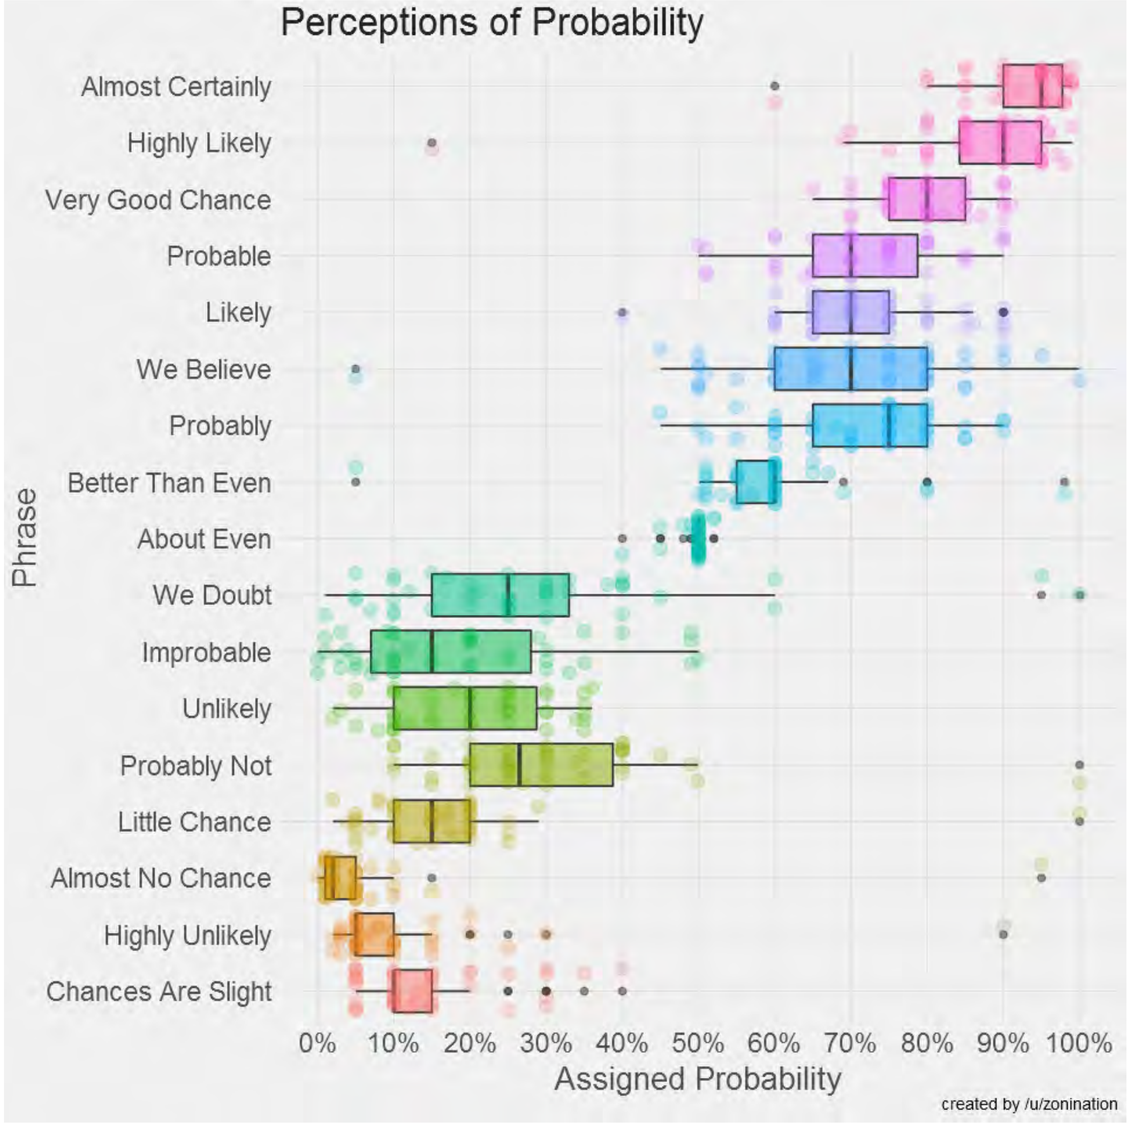




Nützliche Ergänzungen für Distribution Charts

Kombination verschiedener Distribution Charts

- die Kombination verschiedener Visualisierungen bietet vielfältigere Einblicke, erhöht jedoch die Komplexität und führt zu einem komplizierteren Chart



Referenzen

[Munzner 2014] - Munzner, T.: Visualization analysis and design. Boca Raton, FL: CRC Press, AK Peters visualization series. 2014

[Desbarats 2023] - Nicholas Desbarats. Practical Charts & More Practical Charts - Practical Reporting Inc. 2023

[schwabish 2021] - Jonathan Schwabish: Better Data Visualizations, Columbia University Press, 2021

[Börner 2015] - Katy Börner: Atlas of Knowledge, The MIT Press, 2015

[Wexler 2017] - Wexler, S., Shaffer, J., Cotgreave, A.: The Big Book of Dashboards - Visualizing your Data Using Real-World Business Scenarios, Wiley, 2017

[Park et al. 2018] - Park, D., Drucker, S. M., Fernandez, R., & Elmqvist, N. (2018). ATOM: A Grammar for Unit Visualizations. IEEE transactions on visualization and computer graphics, 24(12), 3032–3043. https://doi.org/10.1109/TVCG.2017.2785807

[Shneiderman 2008] - Ben Shneiderman. 2008. Extreme visualization: squeezing a billion records into a million pixels. In Proceedings of the 2008 ACM SIGMOD international conference on Management of data (SIGMOD '08). Association for Computing Machinery, New York, NY, USA, 3–12. https://doi.org/10.1145/1376616.1376618

[Kirk 2019] - Andy Kirk: Data Visualisation: A Handbook for Data Driven Design, SAGE Publications Ltd; 2. Edition (21. August 2019)

[Blois et al. 2022] - Filip de Blois, Marian Abels, Raymond de Niet, Jan de Ruiter and Allard Warrink: Visualising Knowledge. Lessons from 25 years of policy-related data visualisation, PBL Netherlands Environmental Assessment AgencY, The Hague, 2022