


Statistik mit R und SPSS


Theoretische Grundlagen

FH OÖ (UAP)

Gerald Lirk

E-Mail: Gerald.Lirk@fh-hagenberg.at








Literatur

- ▶ Weiß: Basiswissen Medizinische Statistik, Springer
- ▶ Schwarze: Grundlagen der Statistik, nwb
- ▶ Sachs, Hedderich: Angewandte Statistik, Springer
- ▶ Schmuller: Statistik mit Excel, Wiley
- ▶ Bühl: SPSS, Pearson

Statistik




Allgemeines Begriff



- ▶ Herkunft (wikipedia)
 - ▶ lat. „statisticum“ = „den Staat betreffend“
 - ▶ Achenwald (1749): Lehre von den Daten über den Staat
 - ▶ J. Sinclair (19.Jh): Sammeln und Auswerten von Daten
- ▶ Bedeutung (Duden)
 - ▶ Wissenschaft von der zahlenmäßigen Erfassung, Untersuchung und Auswertung von Massenerscheinungen
 - ▶ schriftlich fixierte Zusammenstellung, Aufstellung der Ergebnisse von Massenerscheinungen, meist in Form von Tabellen und grafischen Darstellungen


Studien Kategorien




- ▶ **Beobachtungen:** Epidemiologische Studien, Befragung, ...
- ▶ **Experiment:** Merkmal wird aktiv zugewiesen (z.B. klinische Studie)
- ▶ **Prospektiv:** neue Daten erheben
- ▶ **Retrospektiv:** vorhandene Daten nutzen
- ▶ **Längsschnitt:** Merkmal über die Zeit ≥ 2 erheben
- ▶ **Querschnitt:** z.B. Häufigkeit Käufe

Studien

Beobachtungsstudien




Fall-Kontroll-Studie



Prospektive Kohortenstudie



Retrospektive Kohortenstudie



Beobachtung zu Studienbeginn



Krank





Gesund

Selektion zu Studienbeginn




Zu Bestimmen

Allgemeines Übersicht




Allgemeines Aufgaben deskriptive Statistik



- ▶ Zusammenfassen und **Ordnen der Daten** in Tabellen

Positionsnr.	Beschreibung	Menge	Stückpreis
00010-100	Monitor	1	€ 350,00
00010-200	Schreibtischleuchten	3	€ 55,00
00025-275	Telefon	5	€ 85,00
00300-896	Adressbuch	2	€ 15,00

- ▶ Erstellen von **Diagrammen**
- ▶ Berechnen charakteristischer **Kenngrößen** oder Maßzahlen




$$\bar{x} = \frac{2+3+3+2+4+5+1}{7}$$


$$\bar{x} = \frac{20}{7}$$

$$\bar{x} \approx 2,857$$


Allgemeines Ziel- und Einflussfaktoren



Hypothese:
Zigarettenrauchen beeinflusst das Entstehen eines Lungenkarzinoms




Allgemeines Begriffserklärung



- ▶ **Erhebungseinheit** = jene Objekte, über die man Daten erhält
- ▶ **Stichprobe** = Gesamtheit aller Erhebungseinheiten
- ▶ **Grundgesamtheit** = Gesamtheit aller potentiellen Erhebungseinheiten
- ▶ **Merkmal / Variable** = die interessierende Eigenschaft, die an den Erhebungseinheiten beobachtet werden soll
- ▶ **Ausprägung** = Wert, den das Merkmal annimmt -> **Datentyp**
- ▶ **Wertebereich** eines Merkmals = alle Werte, die das Merkmal in allen Erhebungseinheiten annimmt

Allgemeines Datensatz



Zelle, Wert

Header, Semantik

ID	Geburtsdatum	Geschlecht	kg	cm	Blutgruppe	Apgar	Terminab- weichung	Seccio	CTG Fischer	PKU	Körper- temperatur	KH Aufenthalt
1059	20.03.2007 12:52	f	3.68	54	0	10	0	nein	10	neg	37.6	5
1060	24.03.2007 18:33	m	3.52	50	0	8	3	nein	9	neg	37.3	2
1061	25.03.2007 11:08	f	4.03	52	A	9	13	nein	9	neg	36.9	3
1062	21.03.2007 17:02	m	3.27	48	A	10	2	ja	10	neg	37.0	8
1063	01.04.2007 16:34	m	2.92	48	AB	5	-4	nein	6	neg	37.2	3
1064	21.03.2007 09:31	m	2.38	47	A	10	2	nein				
1065	06.04.2007 20:57	f	4.02	51	A	9	-2	ja				
1066	05.04.2007 00:18	m	3.36	51	0	9	-1	nein				
1067	03.04.2007 00:00	m	2.87	47	B	6	0	nein		neg	37.1	5
1068	07.04.2007 06:16	f	3.28	52	0	9		nein		neg		3
1069	05.01.2007 00:00	f	4.34	54	A	10	21	nein	9	neg	37.7	5
1070	13.04.2007 13:22	m	2.80	50	A	8	-2	nein	10	pos	36.7	5
1071	10.04.2007 05:45	f	2.84	51	0	8	5	nein	8	neg	37.0	1
1072	09.04.2007 22:05	f	3.14	51	0	8	-3	ja	9		37.2	5
1073	12.04.2007 17:17	m	2.02	44	0	4	4	nein	5	neg	36.8	5
1074	13.04.2007 11:14	f	3.36	49	B	10	3	nein	10	neg	37.3	4
1075	06.04.2007 18:10	m	2.89	48	A	10	-2	nein	9	neg	37.1	3
1076	07.11.2007 13:18	m	3.28	51	A	9	1	nein	8	neg	37.4	4
1077	04.01.2008 03:08	m	3.35	50	B	9	4	nein		neg	36.9	5
1078	07.12.2007 08:21	m	2.78	48	A	10	-3	nein	8	neg	37.4	5
1079	04.12.2007 07:18	m	3.50	50	A	8	3	nein	9	neg	37.2	3
1080	07.12.2007 09:40	f	3.32	49	0	7	0	ja	7	neg	37.3	8


Zeile = Erhebungseinheit

Spalte = Merkmal / Variable

missing data

Häufigkeiten



Reihen -> Häufigkeiten




- ▶ Statistische Reihe
 - ▶ Ungeordnet
 - ▶ Geordnet
- ▶ Zeitreihe
- ▶ Häufigkeiten
 - ▶ Absolute Häufigkeit
 - ▶ Relative Häufigkeit
- ▶ Verteilung
 - ▶ Eindimensional
 - ▶ mehrdimensional

Häufigkeiten

Darstellung in Diagrammen



Häufigkeiten




aus dem Datensatz

berechnet

Körpergröße	absolute Häufigkeit	relative Häufigkeit	relative Häufigkeit (%)	Summen= häufigkeit
44	1	0.029	2.9%	0.029
45	0	0.000	0.0%	0.029
46	0	0.000	0.0%	0.029
47	4	0.114	11.4%	0.143
48	5	0.143	14.3%	0.286
49	6	0.171	17.1%	0.457
50	6	0.171	17.1%	0.629
51	7	0.200	20.0%	0.829
52	3	0.086	8.6%	0.914
53	0	0.000	0.0%	0.914
54	3	0.086	8.6%	1.000
Summe	35	1	100.0%	

Häufigkeiten

absolute Häufigkeiten




Körpergröße	absolute Häufigkeit
44	1
45	0
46	0
47	4
48	5
49	6
50	6
51	7
52	3
53	0
54	3
Summe	35

= Anzahl Merkmalsausprägungen

Die Summe der abs. Häufigkeiten ergibt immer die Gesamtzahl der Erhebungseinheiten (n)

Häufigkeiten relative Häufigkeiten



x	absolute Häufigkeit	relative Häufigkeit	%
44	1	0.029	2.9%
45	0	0.000	0.0%
46	0	0.000	0.0%
47	4	0.114	11.4%
48	5	0.143	14.3%
49	6	0.171	17.1%
50	6	0.171	17.1%
51	7	0.200	20.0%
52	3	0.086	8.6%
53	0	0.000	0.0%
54	3	0.086	8.6%
Summe	35	1	100.0%

= Relation der Häufigkeiten der einzelnen Erhebungseinheiten zu n

= Anteil der einzelnen Ausprägungen

$$p_i = \frac{h_i}{n}$$


p_i = i-te relative Häufigkeit

h_i = abs. Häufigkeit der i-ten Ausprägung

n = Gesamtzahl der Merkmalsausprägungen

Häufigkeiten

relative Summenhäufigkeiten



x	absolute Häufigkeit	relative Häufigkeit	(%)	Summen= häufigkeit
44	1	0.029	2.9%	0.029
45	0	0.000	0.0%	0.029
46	0	0.000	0.0%	0.029
47	4	0.114	11.4%	0.143
48	5	0.143	14.3%	0.286
49	6	0.171	17.1%	0.457
50	6	0.171	17.1%	0.629
51	7	0.200	20.0%	0.829
52	3	0.086	8.6%	0.914
53	0	0.000	0.0%	0.914
54	3	0.086	8.6%	1.000
Summe	35	1	100.0%	

= kumulierte Häufigkeit




= empirische Verteilungsfunktion

Summierter Anteil der einzelnen Merkmalsausprägungen

$$\sum_{i=1}^i p_i$$


Häufigkeiten

relative Summenhäufigkeiten



Häufigkeiten


Beispiel: Blutgruppen



Ausprägung	Absolute H.	Relative H.
0	$n_1 = 31$	$h_1 =$
A	$n_2 = 35$	$h_2 =$
B	$n_3 = 11$	$h_3 =$
AB	$n_4 = 5$	$h_4 =$
Summe	$n = 82$	100%









Häufigkeiten Kontingenztafel




	Raucher	Nichtraucher	
Männlich	7 (0,09) (0,25) (0,27)	21 (0,26) (0,75) (0,38)	28 (0,34)
Weiblich	19 (0,23) (0,35) (0,73)	35 (0,43) (0,65) (0,63)	54 (0,66)
	26 (0,32)	56 (0,68)	82

Rauchen Frauen häufiger?

Häufigkeiten grafische Darstellung





Merkmalstypen diskret vs. stetig



diskret






stetig






Merkmalstypen

diskret vs. stetig: Google-Abfrage





Merkmalstypen

Klassifikation der Skalenniveaus



▶ **Metrische Skala:**


▶ Intervallskala: Nullpunkt ist festgelegt
z.B. Temperatur in °C

▶ Verhältnisskala: absoluter Nullpunkt
z.B. Cholesteringehalt

▶ **Ordinalskala:** Rangfolge lässt sich ableiten
z.B.: Krebsstadien I-IV, Antibiotikaresistenz

▶ **Nominalskala:** begriffliche Unterscheidung
z.B.: männlich/weiblich, Farben

Merkmalstypen Nominale Daten



Ungeordnete Kategorien

Blutgruppe
Berufsgruppe
Familienstand

Binär: 2 Kategorien


Kauf/Nicht-Kauf
krank/gesund
Exposition ja/nein

nominal ... Nomen

Geburtsdatum Datum tt.mm.jjjj	Apgar-Score <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Geschlecht ☐ m ☐ f	Termin-Abweichung Meine Antwort																				
Gewicht Meine Antwort	Seccio ☐ j ☐ n																				
Größe Meine Antwort	CTG-Fisher <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Blutgruppe ☐ 0 ☐ A ☐ B ☐ AB	PKU ☐ pos ☐ neg																				
	Körpertemperatur Meine Antwort																				

Merkmaltypen

Ordinale Daten



Geordnete Kategorien


Krebsstadien
Schulnoten
Likert-Skalen

ordinal... Ordnung

Geburtsdatum Datum tt.mm.jjjj	Apgar-Score <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Geschlecht ☐ m ☐ f	Termin-Abweichung Meine Antwort																				
Gewicht Meine Antwort	Seccio ☐ j ☐ n																				
Größe Meine Antwort	CTG-Fisher <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Blutgruppe ☐ 0 ☐ A ☐ B ☐ AB	PKU ☐ pos ☐ neg																				
	Körpertemperatur Meine Antwort																				

Merkmalstypen

Metrische (quantitative) Daten



Quantitative Daten


Intervallskaliert
Verhältnisskala

metrisch... Meter

Geburtsdatum Datum tt.mm.jjjj	Apgar-Score <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Geschlecht ☐ m ☐ f	Termin-Abweichung Meine Antwort																				
Gewicht Meine Antwort	Section ☐ j ☐ n																				
Größe Meine Antwort	CTG-Fisher <table><tr><td>1</td><td>2</td><td>3</td><td>4</td><td>5</td><td>6</td><td>7</td><td>8</td><td>9</td><td>10</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td><td>☐</td></tr></table>	1	2	3	4	5	6	7	8	9	10	☐	☐	☐	☐	☐	☐	☐	☐	☐	☐
1	2	3	4	5	6	7	8	9	10												
☐	☐	☐	☐	☐	☐	☐	☐	☐	☐												
Blutgruppe ☐ 0 ☐ A ☐ B ☐ AB	PKU ☐ pos ☐ neg																				
	Körpertemperatur Meine Antwort																				

Merkmaltypen

Metrische (quantitative) Daten



Intervallskalierte Daten

numerische Daten,
die man addieren und subtrahieren kann
es gibt keinen Nullpunkt ->
keine Verhältnisse möglich

Kalender-Jahreszahlen
Temperatur in °C
IQ

Mittelwerte von 50 Jahren 1964-2014


„Pankrazi, Servazi, Bonifazi sind drei frostige Bazi. Und zum Schluss fehlt nie die kalte Sophie.“ die Eiseiligen, von 12.-15. Mai



https://www.zamg.ac.at/cms/de/klima/news/die-eiseiligen-seiten-frostig-und-trotzdem-oft-verlaesslich?image_mini

Merkmalstypen


Metrische (quantitative) Daten



Verhältnisskala


numerische Daten,
die man addieren, subtrahieren, aber auch
multiplizieren und dividieren kann
es gibt einen Nullpunkt ->
Verhältnisse möglich

Alter
Einkommen
Blutdruck



Merkmalstypen

Time-to-Event Daten



Hybridvariablen


quantitativer Anteil = Zeit
binärer Anteil = Event j/n

Zeit, bis zu dem Ereignis stattfindet
Einsatzgebiet: Überlebensanalysen


Problem: Zensierung

Time to

- ... death
- ... heart attack
- ... subscription cancellation
- ... component failure
- ... dismissal



Merkmalstypen Beispiele



Merkmal	Ausprägung		
Familienstand	ledig (=1) verheiratet (=2) geschieden (=3) verwitwet (=4)	Nominal	Diskret
Zeiten bei 100m Lauf	11.21 sec., 12.03 sec, ...	Metrisch	Stetig
Preis einer Ware	29,90 €, 34,90 €, ...	Metrisch	Diskret
Platzierung in 100m Lauf	1., 2., 3., ...	Ordinal	Diskret
Patienten pro Tag	3.267, 583, ...	Metrisch	Diskret
Beurteilung des Gesundheitszustandes	1 = sehr gut 2 = gut 3 = durchschnittlich 4 = schlecht 5 = sehr schlecht	Ordinal	Diskret
Flüssigkeitsmenge	1,045 l, 546 ml 3,65 ml	Metrisch	Stetig

Diagramme

