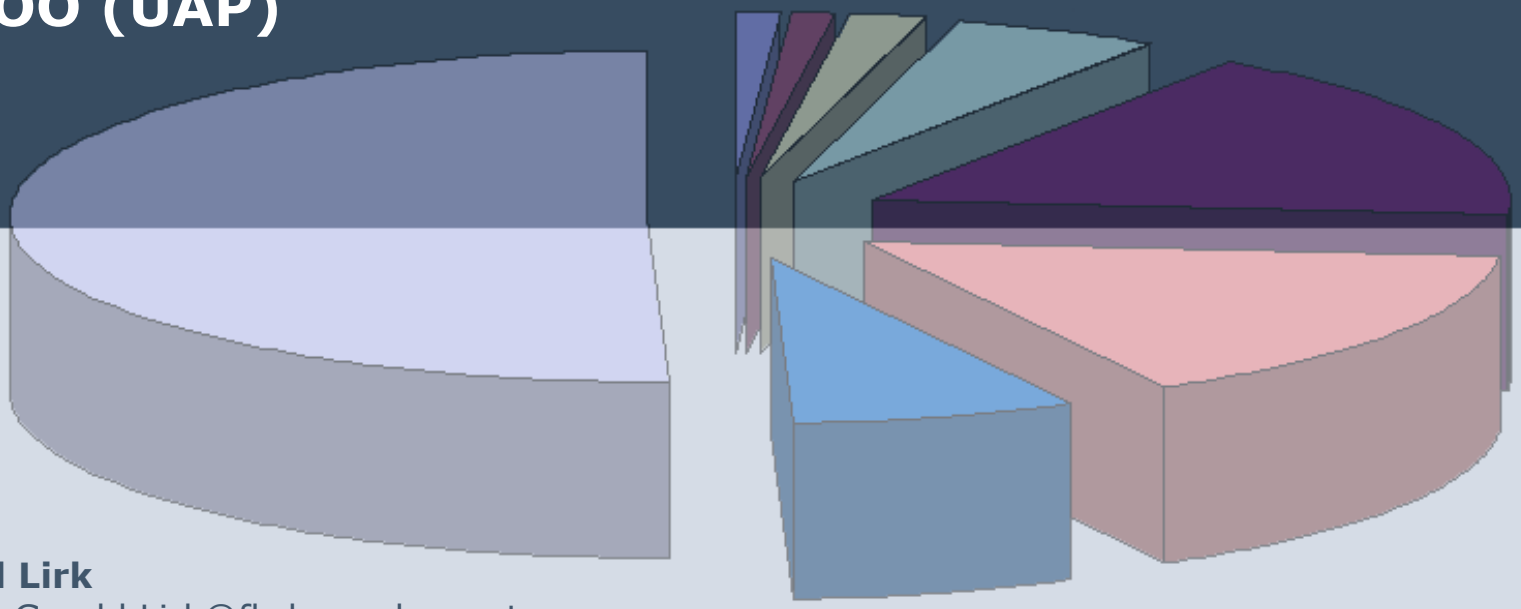
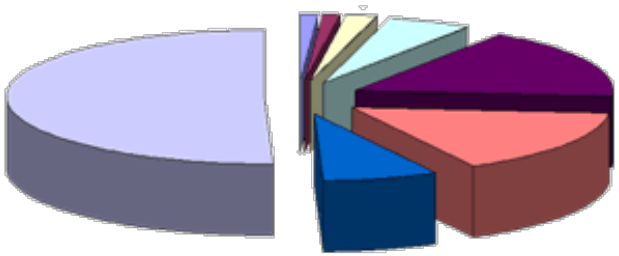
Statistik mit R und SPSS
Deskriptive Statistik

FH OÖ (UAP)



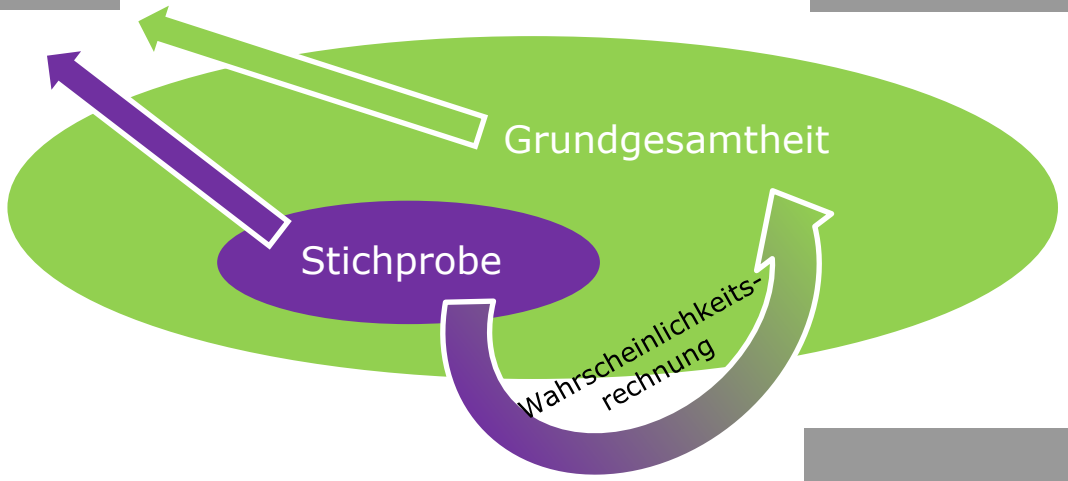
Gerald Lirk
E-Mail: Gerald.Lirk@fh-hagenberg.at

Allgemeines
Übersicht



Beschreibende (deskriptive) Statistik

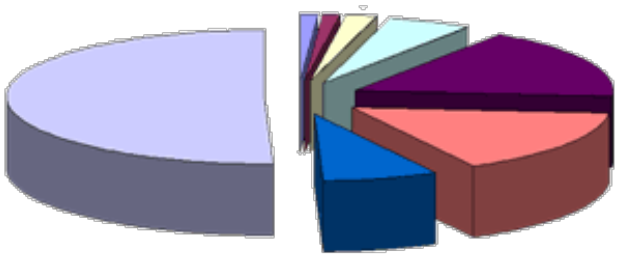
Explorative (hypothesen-generierende, analytische, Data-Mining) Statistik



Schließende (induktive, inferentielle, beurteilende) Statistik

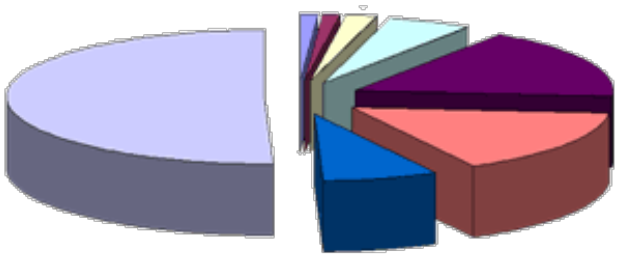
Stichproben Kennzahlen („sample statistics"):
- Mittelwert, Standardabweichung, Relative Häufigkeiten
- Relative Risiken (Rate ratio, Risk ratio, Odds ratio)
- Korrelations- / Regressionskoeffizienten
- etc.

Allgemeines
Aufgaben der deskriptiven Statistik

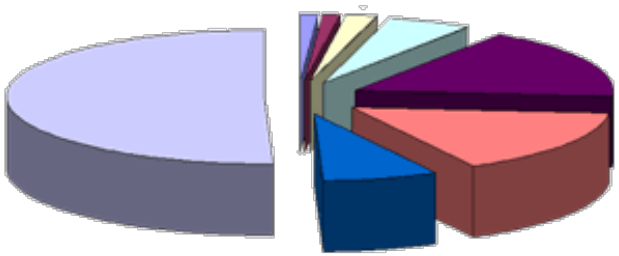


- Zusammenfassen und **Ordnen der Daten** in Tabellen
- Erstellen von **Diagrammen**
- Berechnen charakteristischer **Kenngrößen** oder Maßzahlen

Merkmalstypen
Klassifikation der Skalenniveaus



- **Metrische Skala:**
  - Intervallskala: Nullpunkt ist festgelegt
    z.B. Temperatur in °C
  - Verhältnisskala: absoluter Nullpunkt
    z.B. Cholesteringehalt
- **Ordinalskala**: Rangfolge lässt sich ableiten
  z.B.: Krebsstadien I-IV, Antibiotikaresistenz
- **Nominalskala**: begriffliche Unterscheidung
  z.B.: männlich/weiblich, Farben



Beschreibung eines Merkmals
Zusammenfassung Lagemaße

Qualitative Daten

nominal | ordinal

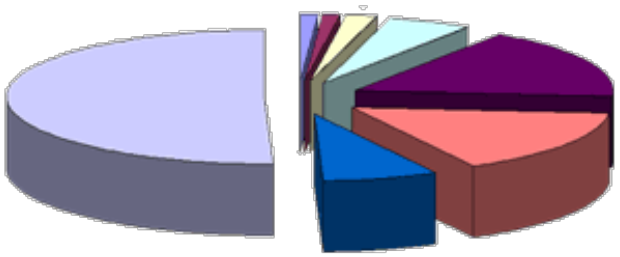
Quantitative Daten

metrisch

Mittelwert

Median

Modus

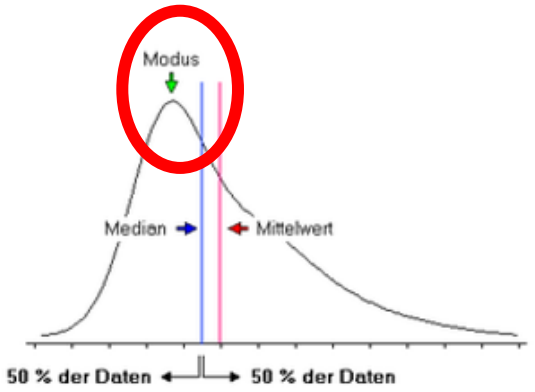


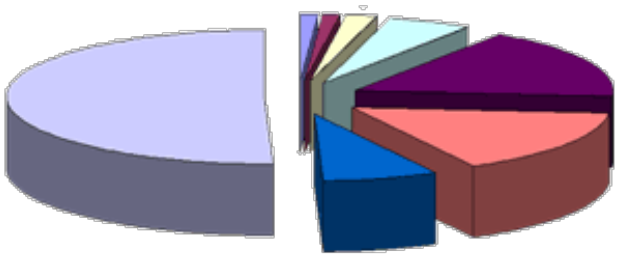
Beschreibung eines Merkmals
Modus

- = häufigster Wert
- = größte abs/rel Häufigkeit
- MODALWERT(x_i – x_n)
- modeest::*mfv*(x_1-x_n)
- Anwendbar bei **allen Skalenniveaus**
- Ausreißer beeinflussen den Modus nicht



https://www.watson.ch/imgdb/a75c/Qx,A,0,0,971,556,404,231,161,92/7254181846422570



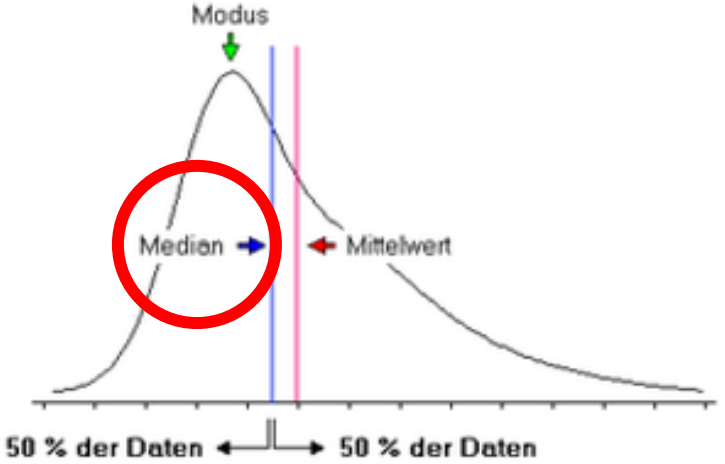


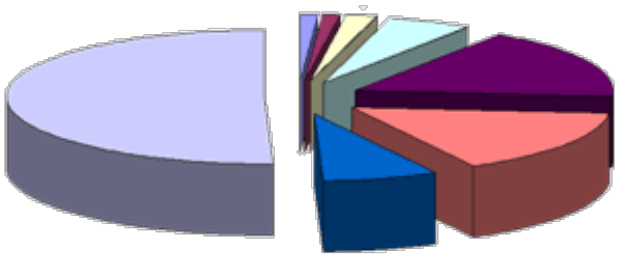
Beschreibung eines Merkmals
Median

- **Rangliste** = Sortierte Werte
- = **Zentralwert**
- = Mittlere Position in einer geordneten Liste
- *median(x_1-x_n)*
- *quantile(x_1-x_n, probs)*
- *quantil(x_1-x_n, probs)*



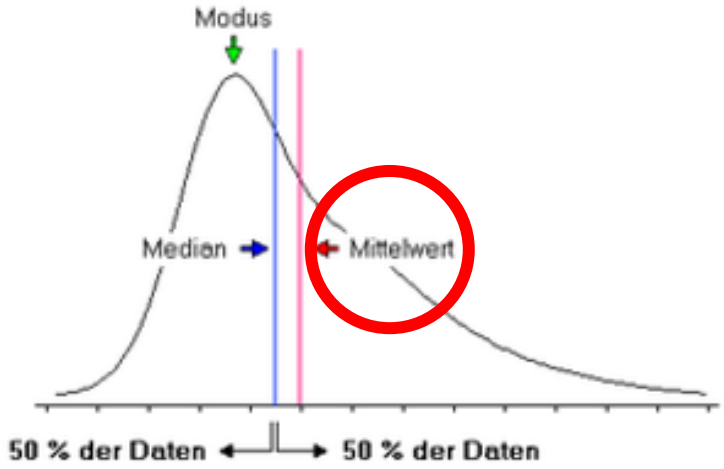
https://digit.wdr.de/entries/57638?index=2



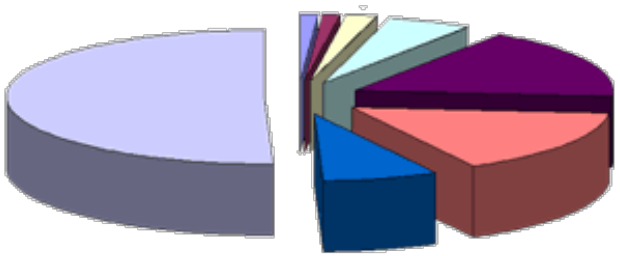


Beschreibung eines Merkmals
Arithmetisches Mittel

- **Durchschnitt**
- *MITTELWERT(x_1-x_n)*
- *mean(x_1-x_n)*
- CAVE: Eingabe des Parameters *na.rm=T*

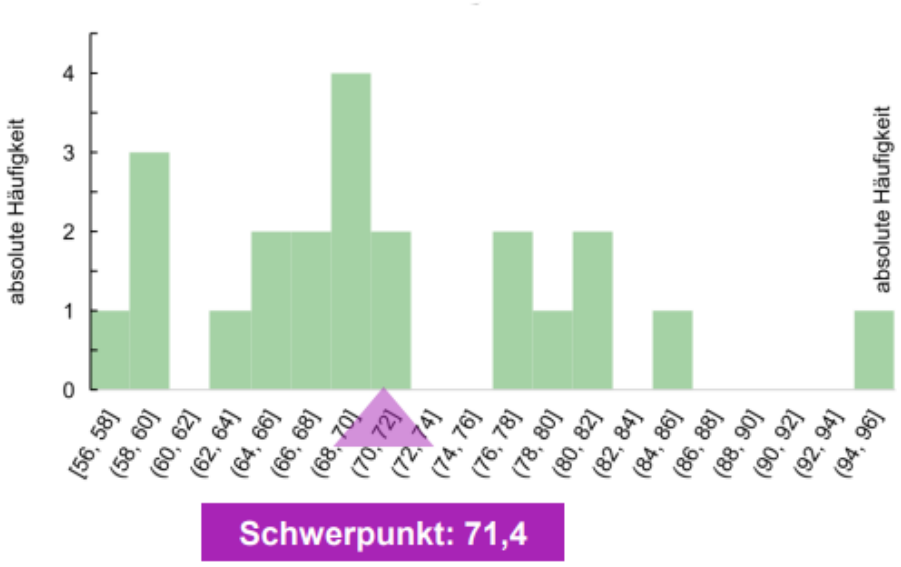


$$\bar{x}_{arith} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

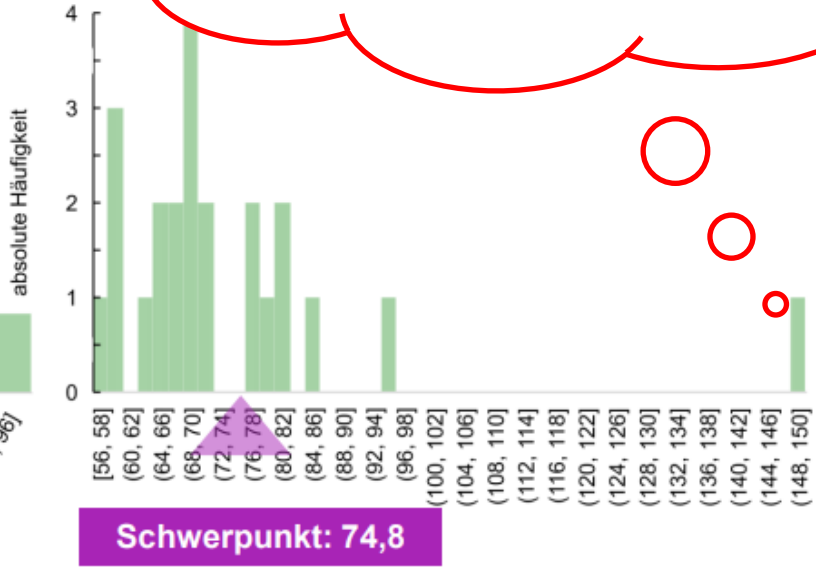


Beschreibung eines Merkmals
Arithmetisches Mittel

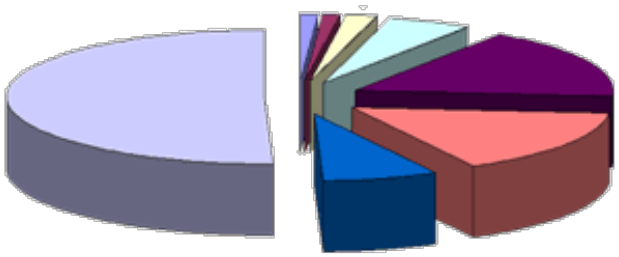
Ausreißer beeinflussen
das arithmetische Mittel
„Kraft * Kraftarm“



Schwerpunkt: 71,4



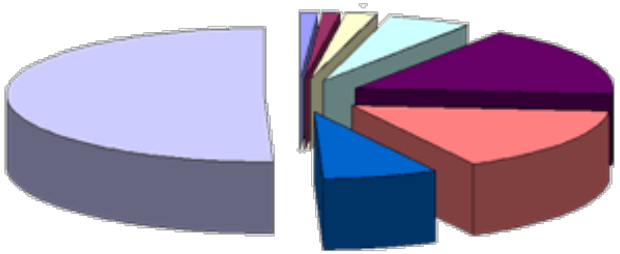
Schwerpunkt: 74,8



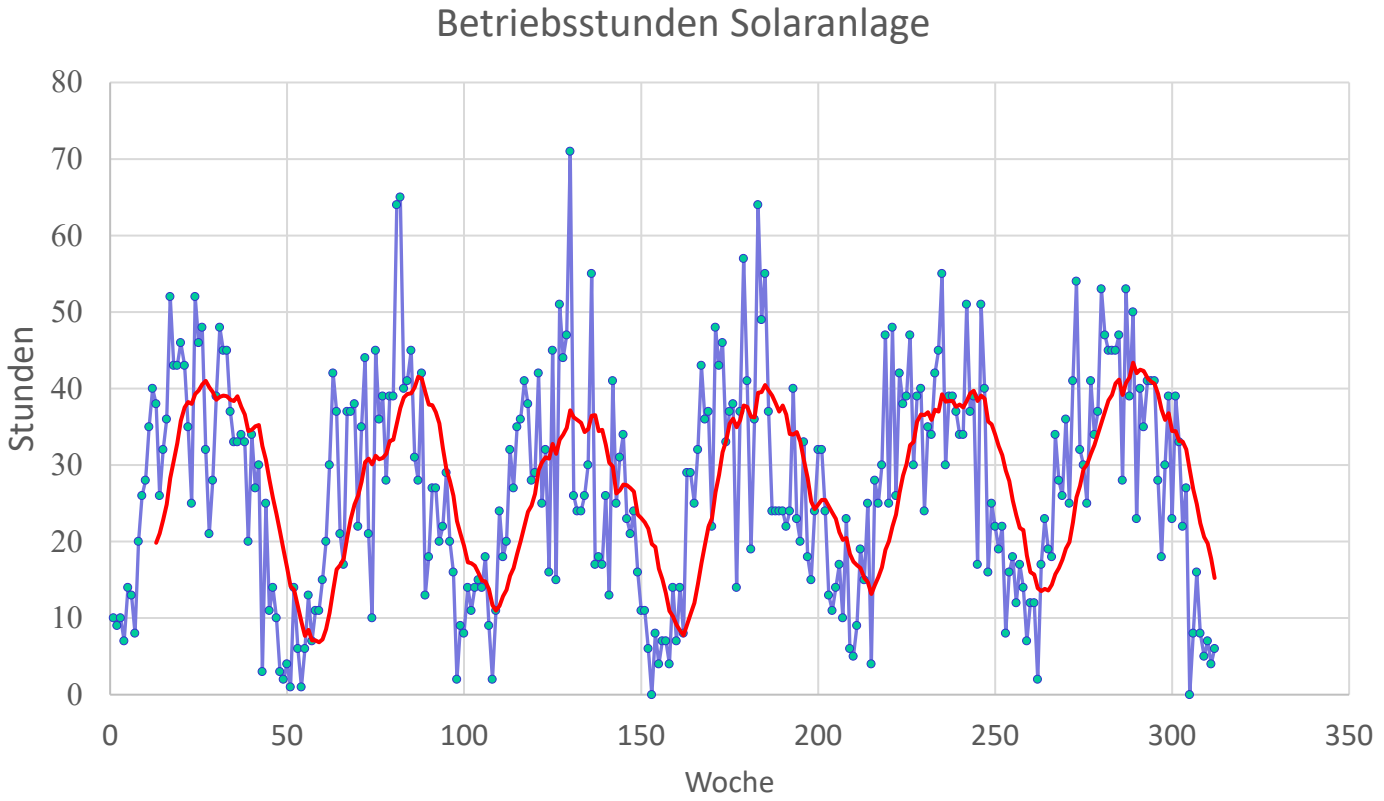
Beschreibung eines Merkmals
Geometrisches Mittel

- GEOMITTEL(x_1-x_n)
- *tbrf::gm_mean(x_1-x_n)*
- Verwendung bei **relativen Änderungen**
- Unterschied lässt sich durch einen Quotienten beschreiben

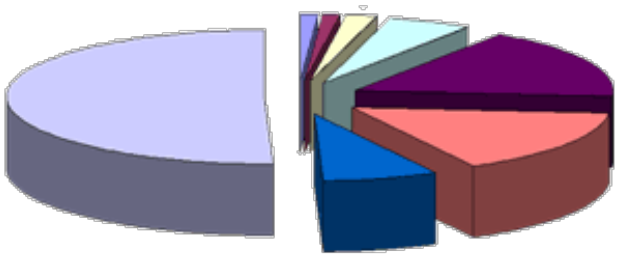
$$\bar{x}_{\text{geom}} = \sqrt[n]{\prod_{i=1}^{n} x_i} = \sqrt[n]{x_1 \cdot x_2 \cdot \ldots \cdot x_n}$$



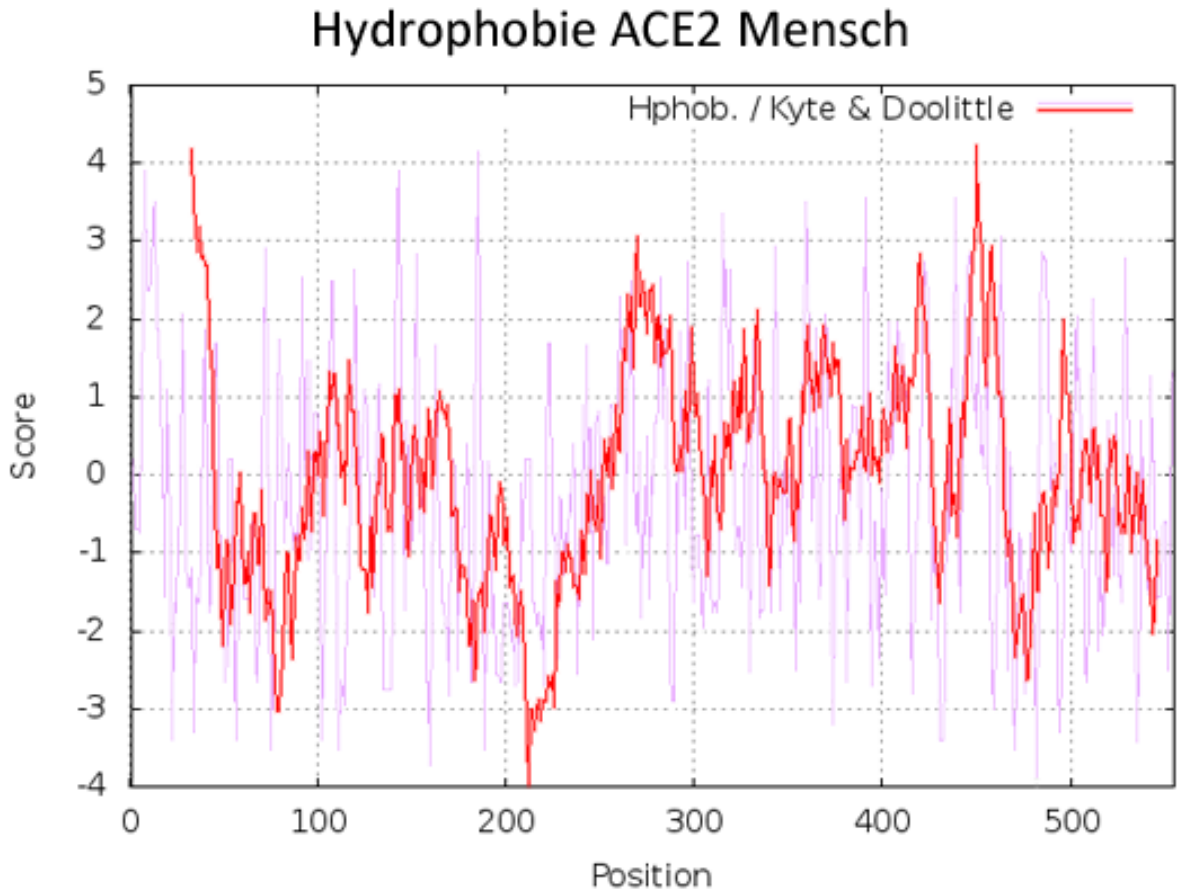
Beschreibung eines Merkmals
Gleitendes Mittel

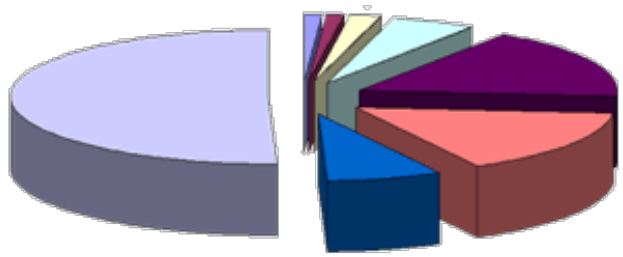


filter(x, filter)



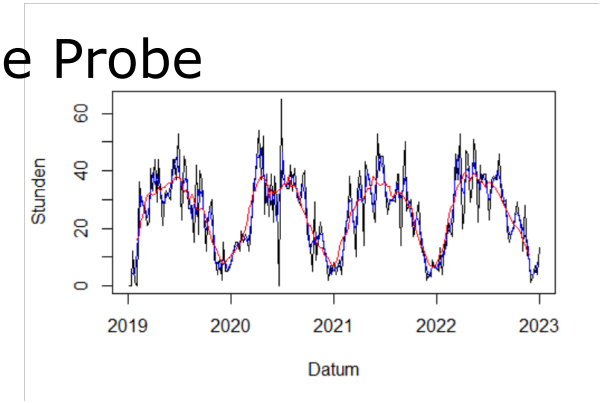
Beschreibung eines Merkmals
Gleitendes Mittel

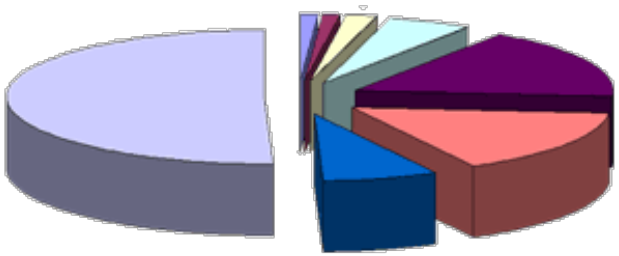




Beschreibung eines Merkmals
AUFGABE 1: Lagemasse

- Berechnen Sie vom Vektor
  `groesse <- c(158,181,178,166,175,181,162,185,190,167,181,177)`
  den Modus, Median und das arithmetische Mittel
  Berechnen Sie das 5., 20., 80. und 95. Perzentile.
- Über 5 Tage wurde der Verkaufserlös ermittelt:
  `tage <- c(1000,1200,1300,1500,1600)`
  - Wie groß ist die durchschnittliche %-Änderung des Erlöses?
  - Machen Sie mit diesem ermittelten Wert die Probe
- Erstellen Sie ein Liniendiagramm mit Rohdaten und gewichteten Mittelwerten (3 und 10 Tage) für Solar.csv





Beschreibung eines Merkmals
Zusammenfassung Streuungsmaße

Qualitative Daten

nominal | ordinal

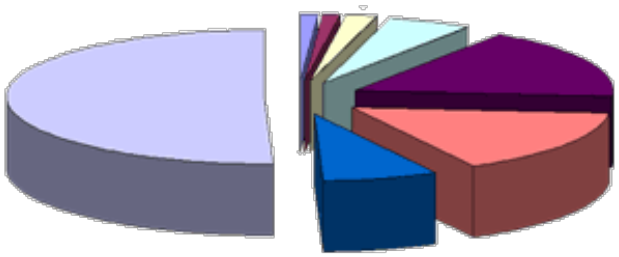
Quantitative Daten

metrisch

Spannweite, SD, Varianz, v

IQR

Variation Ratio



Beschreibung eines Merkmals
Variation Ratio

- Streuungsmaß bei **nominalen** Daten
- Anteil der Daten, die nicht zur Modus-Klasse gehören
- Anwendung selten

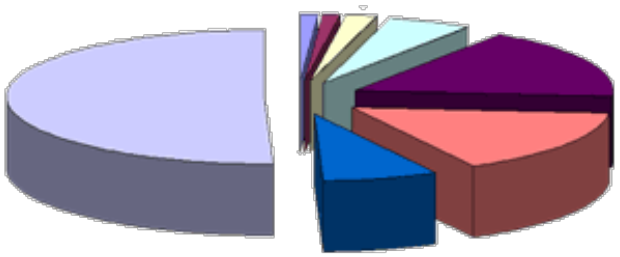
$$vr = 1 - p_{modus}$$

Blutgruppe	Anzahl Babys
0	14
A	12
B	7
AB	2

```
bg <- c(14, 12, 7, 2)
vr <- 1-max(bg)/sum(bg)
```

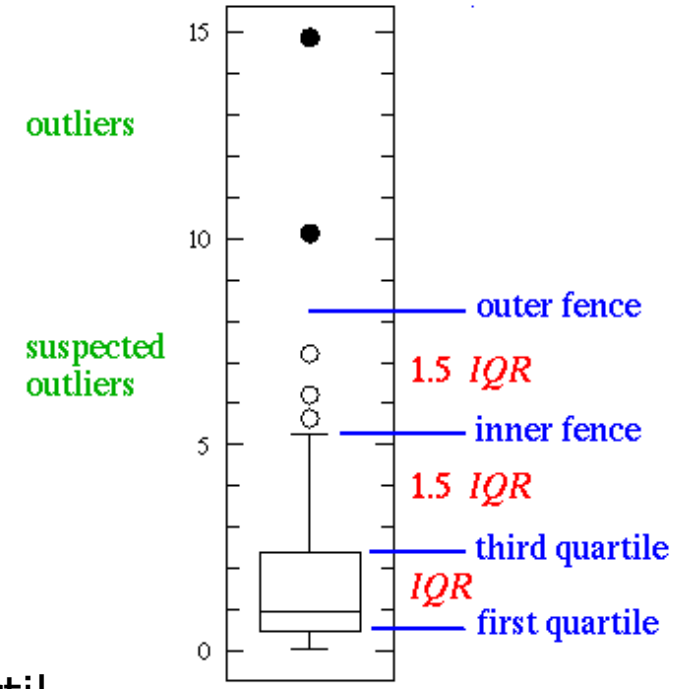
- Probieren Sie VR aus vr.csv zu berechnen

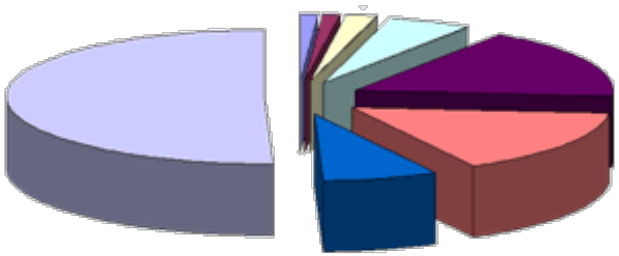
```
table(x)
```



IQR
Box and Whiskers Plot

- Box
  - untere Begrenzung: 1. Quartil
  - Linie: Median
  - obere Begrenzung: 3. Quartil
- Whiskers
  - Oberer Whisker: Q3+1.5*IQR (nächst < Wert)
  - Unterer Whisker: Q1-1.5*IQR (nächst > Wert)
- Punkte
  - Ausreißer (milde A.): 1.5-3*IQR von 1./3. Quartil
  - Extremwert (starke A.): >3*IQR vom 1./3.Quartil
- *IQR*(x_1-x_n)



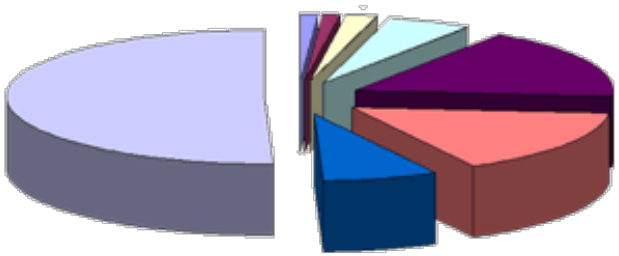


Beschreibung eines Merkmals
Spannweite



www.spektrum.de/fm/912/thumbnails/Wei__kopfseeadler-iStock-172208946_BirdImages.jpg.4572778.jpg

- Range
- Max - Min
- Von Ausreißern beeinflusst

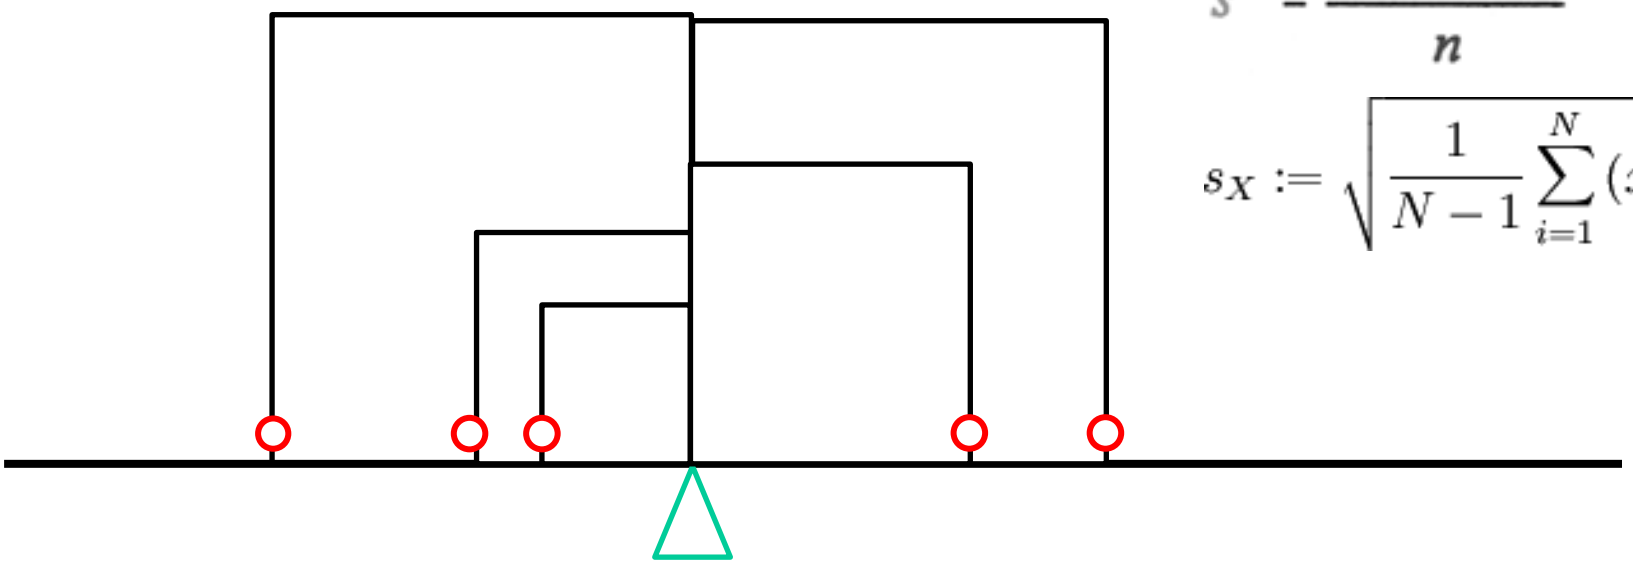


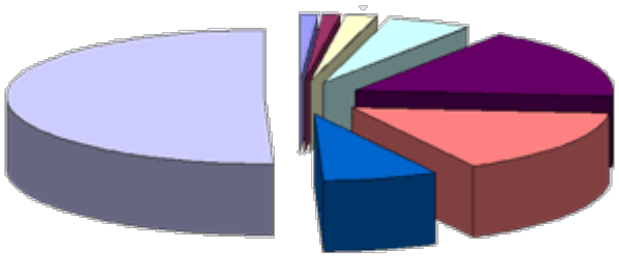
Beschreibung eines Merkmals
Varianz & SD

- Varianz (s^2) mittlere **Abweichung²** der Werte von μ
- **Standardabweichung** s = Streuung = √ der Varianz
- *sd(x_1-x_n)*
- *STABW(x_1-x_n)*

$$s^2 = \frac{\sum_{i=1}^{n} (x_i - \bar{x})^2}{n}$$

$$s_X := \sqrt{\frac{1}{N-1} \sum_{i=1}^{N} (x_i - \bar{x})^2}$$





Beschreibung eines Merkmals
AUFGABE: Streuungsmasse

- Berechnen Sie vom Vektor
  ```
  groesse <-
  c(158,181,178,166,175,181,162,185,190,167,181,177)
  ```
  - die Spannweite,
  - den Interquartilsabstand,
  - die Standardabweichung und
  - die Varianz
- Erstellen Sie einen Boxplot dieses Vektors